



DOCTORADO EN
**INTELIGENCIA
ARTIFICIAL**



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA



UCSC



UNIVERSIDAD DEL BÍO-BÍO

Aprendizaje automático - Sesión 5.2


Support Vector Regression

Doctorado en Inteligencia Artificial

Jorge Portilla

Departamento de Electrónica e Informática
Universidad Técnica Federico Santa María
Concepción, Chile

Support Vector Machine (SVM)



SVM es una ampliación del SVC para adaptarse a límites de clase no lineales. Las SVM están pensadas para la clasificación binaria, en la que existen dos clases.

Truco del Kernel en SVM

- Supongamos que cada vez que el producto interno (19) aparece en la representación (20), lo reemplazamos con una generalización del producto interno de la forma

$$\Omega(x_i, x_{i'}) \quad (22)$$

donde Ω es una función que denominamos *kernel*.

- Un kernel es una función que cuantifica la similitud entre dos observaciones. Por ejemplo, podríamos tomar:

$$\Omega(x_i, x_{i'}) = \sum_{j=1}^p x_{ij} x_{i'j}, \quad (23)$$

lo que nos devolvería el SVC estándar. La ecuación (23) se conoce como el *kernel lineal* porque el clasificador es lineal en las características. Este kernel lineal cuantifica la similitud de un par de observaciones utilizando la correlación de Pearson estándar.

- Para esto se utiliza una función kernel $\Omega(\mathbf{x}_i, \mathbf{X}_t)$ que traslada los vectores originales de entrada $\mathbf{X}_t$ a un espacio de alta dimensión para asegurar su separabilidad lineal a través de estos hiperplanos.
- Encontrar el hiperplano óptimo que separa dos clases es equivalente a resolver el problema de optimización descrito en la siguiente expresión:

$$\mathbf{y} = \sum_{i=1}^N \mathbf{w}_i \Omega(\mathbf{x}_i, \mathbf{X}_t) + \mathbf{b} \quad (1)$$

- En que $\mathbf{y}$ es el resultado de la clasificación, $\mathbf{w}_i$ es el peso i -ésimo adaptado al modelo, $\mathbf{x}_i$ es el vector de soporte i -ésimo y $\mathbf{b}$ es el bias o sesgo del hiperplano con respecto al origen.

- En general, el objetivo es calcular los valores de la matriz de pesos $\mathbf{w}^*$ que cumplan con (2).

$$(\mathbf{w}^*, \mathbf{b}) =_{w,b,\xi} \frac{1}{2} |\mathbf{w}^*|^2 + \mathbf{C} \sum_{i=1}^S \xi_i \quad (2)$$

$$\mathbf{y}_i(\mathbf{w}^* \mathbf{x}_i + \mathbf{b}) \geq 1 - \xi_i \quad , \quad \xi_i \geq 0 \quad (3)$$

- Donde S hace referencia al número de kernels y $\mathbf{C}$ es un parámetro de penalización elegido durante el entrenamiento.
- La ecuación (2) está sujeta a la restricción (3), debido a que dentro del problema de optimización se introducen **variables de holgura** cuando los datos no son reparables para permitir violar las restricciones*. ξ_i es el vector de holgura que hace referencia al tamaño de dichas violaciones.

*Chapelle, O., Haffner, P., Vapnik, V. N. (1999). Support vector machines for histogram-based image classification. IEEE transactions on Neural Networks, 10(5), 1055-1064.

Support Vector Regression (SVR)

- Una variante del algoritmo **SVM** diseñada para problemas de **regresión**.
- Aproximar la relación entre variables de entrada y una variable continua de salida minimizando el error de estimación.
- A diferencia de SVM, SVR:
 - No busca separar clases.
 - Busca ajustar un **hiperplano** que prediga valores continuos dentro de un margen de tolerancia ε .

■

$$\mathbf{y} = \sum_{i=1}^N \mathbf{w}_i \Omega(\mathbf{x}_i, \mathbf{X}_t) + \mathbf{b} \quad (4)$$

Problema de optimización en SVR

$$(\mathbf{w}^*, \mathbf{b}) = \arg \min_{\mathbf{w}, \mathbf{b}, \xi, \xi^*} \frac{1}{2} \|\mathbf{w}^*\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*)$$

Sujeto a:

$$\begin{cases} \mathbf{y} - \mathbf{w}^* \mathbf{x}_i - \mathbf{b} \leq \varepsilon + \xi_i \\ \mathbf{w}^* \mathbf{x}_i + \mathbf{b} - \mathbf{y} \leq \varepsilon + \xi_i^* \\ \xi_i, \xi_i^* \geq 0 \end{cases}$$

- C : factor de penalización sobre desviaciones.
- ε : ancho del tubo de tolerancia.
- ξ_i, ξ_i^* : variables de holgura que permiten violaciones al margen.

- SVR extiende SVM para problemas de regresión.
- El ε -tube define un margen de tolerancia alrededor del hiperplano.
- Solo los vectores fuera del tubo son **support vectors**.
- El uso de kernels permite manejar relaciones no lineales.



UNIVERSIDAD TÉCNICA
FEDERICO SANTA MARÍA

Aprendizaje automático - Sesión 5.2

Support Vector Regression

Doctorado en Inteligencia Artificial

Jorge Portilla

Departamento de Electrónica e Informática
Universidad Técnica Federico Santa María
Concepción, Chile