



DOCTORADO EN
**INTELIGENCIA
ARTIFICIAL**



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA



UCSC



UNIVERSIDAD DEL BÍO-BÍO

Aprendizaje automático - Sesión 5

Support Vector Machine

Doctorado en Inteligencia Artificial

Jorge Portilla

Departamento de Electrónica e Informática
Universidad Técnica Federico Santa María
Concepción, Chile

Introducción a Support Vector Machine

- Las máquinas de soporte vectorial (SVM) son un tipo de algoritmo de aprendizaje automático supervisado que se utiliza para tareas de clasificación y regresión.
- Se utilizan ampliamente en diversos campos, como el reconocimiento de patrones, el análisis de imágenes y el procesamiento del lenguaje natural.
- El algoritmo SVM es ampliamente utilizado, ya que puede realizar tareas de clasificación tanto lineales como no lineales.
- Cuando los datos no son linealmente separables, se utilizan **funciones de kernel** para transformar los datos en un espacio de mayor dimensión que permita la separación lineal.

SVMs were developed in the 1990s by Vladimir N. Vapnik and his colleagues, and they published this work in a paper titled "Support Vector Method for Function Approximation, Regression Estimation, and Signal Processing"¹ in 1995.

- La máquina de soporte vectorial es una generalización de un clasificador sencillo e intuitivo llamado clasificador de margen máximo (*maximal margin classifier*).
 - Infortunadamente, requiere que las clases sean separables por una frontera lineal.
- *Support vector classifier*, es una extensión del *maximal margin classifier*.

- La máquina de soporte vectorial es una generalización de un clasificador sencillo e intuitivo llamado clasificador de margen máximo (*maximal margin classifier*).
 - Infortunadamente, requiere que las clases sean separables por una frontera lineal.
- *Support vector classifier*, es una extensión del *maximal margin classifier*.
- En general, se confunden estos términos y se usan equivocadamente de forma intercambiada.

¿Qué es un hiperplano?

- La generación de un clasificador SVM se basa en **encontrar un hiperplano** que separe las distintas clases existentes en los vectores de los datos de entrenamiento.
- Un **hiperplano** es una frontera de decisión que separa puntos de datos en diferentes clases en un espacio de alta dimensión.
 - En un espacio 2D, un hiperplano es simplemente una línea que separa los puntos de datos en dos clases.
 - En un espacio 3D, un hiperplano es un plano que separa los puntos de datos en dos clases.
 - De manera similar, en un espacio N-dimensional, un hiperplano tiene $(N-1)$ dimensiones.

Definición matemática de un hiperplano

En 2D, un hiperplano se define mediante la ecuación:

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 = 0 \quad (1)$$

para los parámetros β_0 , β_1 y β_2 . Cualquier punto $X = (X_1, X_2)^T$ que satisfaga la ecuación (1) está sobre el hiperplano.

Definición matemática de un hiperplano

En 2D, un hiperplano se define mediante la ecuación:

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 = 0 \quad (1)$$


para los parámetros β_0 , β_1 y β_2 . Cualquier punto $X = (X_1, X_2)^T$ que satisfaga la ecuación (1) está sobre el hiperplano.

En el caso p-dimensional:

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p = 0 \quad (2)$$

Hiperplano en p dimensiones, si un punto $X = (X_1, X_2, \dots, X_p)^T$ en un espacio p-dimensional satisface la ecuación (2), entonces X está sobre el hiperplano.

Posición de un punto respecto al hiperplano



- La figura muestra el hiperplano $1 + 2X_1 + 3X_2 = 0$ se muestra. La región azul es el conjunto de puntos para los cuales $1 + 2X_1 + 3X_2 > 0$, y la región púrpura es el conjunto de puntos para los cuales $1 + 2X_1 + 3X_2 < 0^*$.

*ecuación de la recta

Posición de un punto respecto al hiperplano

Cuando un X no satisface la ecuación (2):

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p > 0 \quad (3)$$

Indica que X se encuentra a un lado del hiperplano.

Por otro lado, si:

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p < 0 \quad (4)$$

entonces X se encuentra en el otro lado del hiperplano.

- De este modo, podemos pensar en el hiperplano como una división del espacio p -dimensional en dos mitades.
- Se puede determinar en qué lado del hiperplano se encuentra un punto simplemente calculando el signo del lado izquierdo de la ecuación (2).

Clasificación usando un hiperplano

Consideremos una matriz de datos $\mathbf{X} \in \mathbb{R}^{n \times p}$ con n observaciones en un espacio p -dimensional, donde cada fila $\mathbf{x}_i$ representa una observación:

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ip})^T, \quad i = 1, \dots, n, \quad (5)$$

y cada observación pertenece a una de dos clases: $y_i \in \{-1, 1\}$.


Podemos etiquetar las observaciones de la clase azul como $y_i = 1$ y las de la clase púrpura como $y_i = -1$. Un hiperplano separador tiene la propiedad de que:

$$\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} > 0 \text{ si } y_i = 1, \quad (6)$$

y

$$\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} < 0 \text{ si } y_i = -1. \quad (7)$$

Clasificación usando un hiperplano




- De manera equivalente, un hiperplano separador tiene la propiedad de que:

$$y_i(\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}) > 0, \quad (8)$$

para todo $i = 1, \dots, n$.

Clasificación usando un hiperplano



En la izquierda, la imagen presenta tres hiperplanos separadores en negro, de entre muchos posibles.

En la derecha, se muestra un hiperplano separador en negro. La cuadrícula de color azul y morado indica la regla de decisión utilizada por un clasificador basado en ese hiperplano separador.

Maximal margin classifier


Maximal margin classifier

- En general, si nuestros datos pueden separarse perfectamente mediante un hiperplano, entonces de hecho existirá un número infinito de tales hiperplanos.
- Una elección natural es el hiperplano de margen máximo (también conocido como el hiperplano de separación óptimo máximo), que es el hiperplano de separación que está más alejado de las observaciones de entrenamiento.

Maximal margin classifier

- En general, si nuestros datos pueden separarse perfectamente mediante un hiperplano, entonces de hecho existirá un número infinito de tales hiperplanos.
- Una elección natural es el hiperplano de margen máximo (también conocido como el hiperplano de separación óptimo máximo), que es el hiperplano de separación que está más alejado de las observaciones de entrenamiento.
- Se puede calcular la distancia (perpendicular) de cada observación de entrenamiento a un hiperplano de separación dado.
- La menor distancia al hiperplano se conoce como **margen**.
- El hiperplano de margen máximo es el hiperplano de separación para el que el margen es mayor, es decir, es el hiperplano que tiene la distancia mínima más lejana a las observaciones de entrenamiento.

Maximal margin classifier (2)



- Se espera que un clasificador con un gran margen en los datos de entrenamiento tenga un gran margen en los datos de prueba. Sin embargo, cuando el número de características $p \gg n$, el clasificador de margen máximo puede llevar al overfitting[†].

[†]James, G., Witten, D., Hastie, T., Tibshirani, R. (2023). An introduction to statistical learning with Python. Springer.

Maximal margin classifier (3)

- Tres observaciones de entrenamiento están equidistantes del hiperplano de margen máximo y se encuentran en las líneas punteadas que indican el ancho del margen.
- Estas tres observaciones se denominan **vectores de soporte (SV)**.
- El hiperplano de margen máximo depende directamente de los **SV**, y si estos puntos se movieran, el hiperplano también se movería.
- El hiperplano no depende de las demás observaciones; mover otras observaciones no afectaría al hiperplano, siempre y cuando no crucen los límites establecidos por el margen.
- Esta propiedad clave, que el hiperplano depende solo de un pequeño subconjunto de observaciones (SV), es fundamental para **support vector classifier (SVC)** y **support vector machine (SVM)**.

Construction of the Maximal Margin Classifier

- Consideramos el problema de construir un MMC a partir de un conjunto de observaciones de entrenamiento $(x_1, y_1), \dots, (x_n, y_n)$, donde $x_i \in \mathbb{R}^p$ y $y_i \in \{-1, 1\}$.

Problema de optimización:

$$\underset{\beta_0, \beta_1, \dots, \beta_p, M}{\text{maximize}} \quad M \quad (9)$$

$$\text{subject to} \quad \sum_{j=1}^p \beta_j^2 = 1^\dagger \quad (10)$$

$$y_i (\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip}) \geq M \quad \forall i = 1, \dots, n \quad (11)$$

- La ecuación $y_i (\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip}) \geq M$ garantiza que todas las observaciones estén correctamente clasificadas con un margen M .

[†]asegura que los coeficientes estén normalizados

Construction of the Maximal Margin Classifier (2)

- El objetivo es maximizar M , que representa el margen.
- Si M es **positivo**, significa que todas las observaciones están en el lado correcto del hiperplano con respecto a sus clases.
- La restricción en la ecuación (11) garantiza que cada observación esté en el lado correcto del hiperplano, siempre y cuando M sea positivo.
- Aunque $\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} = 0$ define un hiperplano, también lo hace $k(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) = 0$ para cualquier $k \neq 0$. Sin embargo, la restricción en (10) asegura que la distancia perpendicular del i -ésimo punto al hiperplano sea dada por $y_i(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip})^{\S\P}$.

[§]Asegura que la distancia perpendicular desde cada punto al hiperplano esté correctamente definida y no sea afectada por un factor de escala k

[¶] k solo escala la magnitud, pero no altera la dirección o la ubicación del hiperplano

^{||}Sin la normalización ((10)), la distancia sería dependiente de k . Esto significa que, si multiplicamos todos los coeficientes por una constante k , las distancias entre los puntos y el hiperplano cambiarían

Construction of the Maximal Margin Classifier (3)

- Las restricciones (10) y (11) aseguran que cada observación esté en el lado correcto del hiperplano y al menos a una distancia M del hiperplano.
- El valor M representa el margen de nuestro hiperplano.
- El problema de optimización elige $\beta_0, \beta_1, \dots, \beta_p$ para maximizar M , obteniendo así el hiperplano de margen máximo.
- ¿Como se resuelve el problema de optimización?

Interpretación geométrica


- La **distancia euclidiana** de un punto x_j al plano:

$$\frac{\sum_{j=1}^m w_j x_j + b}{\|w\|} = \frac{\langle w, x_j \rangle + b}{\|w\|}$$

■


$$\|w\| = \sqrt{\langle w \cdot w \rangle}$$

El numerador mide cuánto “se desvía” el punto respecto al plano.



w define la dirección del hiperplano y es perpendicular al hiperplano, y $\frac{b}{\|w\|}$ determina la distancia del hiperplano al origen en relación con la magnitud de w .

Resolver el problema de optimización



- Las representaciones **primal** y **dual** son dos maneras de formular y resolver problemas de optimización, como los que surgen en algunos problemas de clasificación como SVM.
- Estas dos representaciones están relacionadas a través del **método de multiplicadores de Lagrange**.

Optimización para el Hiperplano Óptimo

- Encontrar el hiperplano óptimo que separa dos clases equivale a resolver el problema de optimización

$$\begin{aligned} & \max_{\beta, \beta_0} M \\ \text{Sujeto a } & y_i \frac{\langle \beta, x \rangle + \beta_0}{\|\beta\|} \geq M, \quad i = 1, \dots, m \end{aligned}$$

- Si elegimos $M = \frac{1}{\|\beta\|}$, el problema anterior es equivalente a

$$\begin{aligned} & \min_{\beta, \beta_0} \|\beta\|^{2**} \\ \text{Sujeto a } & y_i \frac{\langle \beta, x \rangle + \beta_0}{\|\beta\|} \geq 1, \quad i = 1, \dots, m \end{aligned}$$

- Las restricciones definen un margen de decisión $\gamma = \frac{1}{\|\beta\|_2}^{\dagger\dagger}$

**Minimizar $\|\beta\|^2$ (la norma L_2 al cuadrado) es lo mismo que minimizar $\|\beta\|$, con una diferencia importante: minimizar el cuadrado es más conveniente desde el punto de vista matemático y computacional (convexidad).

$\dagger\dagger$ norma l_2

Lagrangiano

- El **Lagrangiano** es una función que combina la función objetivo que queremos optimizar (minimizar o maximizar) con las restricciones del problema, usando multiplicadores de Lagrange.
- En general, si queremos optimizar una función $f(x)$ sujeta a restricciones $g_i(x) = 0$, el Lagrangiano se define como:

$$L(x, \alpha) = f(x) + \sum_i \alpha_i g_i(x)$$

Donde:

- $f(x)$ es la función objetivo que estamos optimizando.
- $g_i(x)$ son las restricciones del problema.
- α_i son los multiplicadores de Lagrange, que penalizan las violaciones de las restricciones.

Lagrangiano Primal

- Por lo tanto, el **Lagrangiano primal** es:

$$L_P(\beta, \beta_0, \alpha) = \frac{1}{2} \langle \beta, \beta \rangle - \sum_{i=1}^m \alpha_i [y_i (\langle \beta, x_i \rangle + \beta_0) - 1]$$

- La restricción $\langle \beta, x \rangle + \beta_0 \geq 1$ se reescribe así: $\langle \beta, x \rangle + \beta_0 - 1 \geq 0$
- Donde los $\alpha_i \geq 0$ son los multiplicadores de Lagrange.
- $\frac{1}{2} \langle \beta, \beta \rangle = \frac{1}{2} \|\beta\|^2$ es la función objetivo (minimizando la norma).
- Este es un problema de programación no-lineal convexa
 - La función objetivo es convexa.
 - Los puntos que satisfacen las restricciones forman un conjunto convexo.

Lagrangiano Dual

- Derivando respecto de β y β_0 , tenemos que:

$$\frac{\delta L_P(\beta, \beta_0, \alpha)}{\delta \beta} = \beta - \sum_{i=1}^m y_i \alpha_i x_i = 0$$

$$\frac{\delta L_P(\beta, \beta_0, \alpha)}{\delta \beta_0} = \sum_{i=1}^m y_i \alpha_i = 0$$

- Utilizando estas relaciones en el Primal obtenemos:

$$\begin{aligned} L_P(\beta, \beta_0, \alpha) &= \frac{1}{2} \langle \beta, \beta \rangle - \sum_{i=1}^m \alpha_i [y_i (\langle \beta, x_i \rangle + \beta_0) - 1] \\ &= \frac{1}{2} \sum_{i,j} y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle - \sum_{i,j} y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle + \sum_{i=1}^m \alpha_i \end{aligned}$$

- Finalmente, el Lagrangiano dual $L_D(\beta, \beta_0, \alpha)$ es:

$$L_D(\beta, \beta_0, \alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j} y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle$$

Lagrangiano Dual (2)

- El Lagrangiano dual $L_D(\beta, \beta_0, \alpha)$ es:

$$L_D(\beta, \beta_0, \alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j} y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle$$

- También se conoce como la **Wolfe dual**.
- Se logra una solución en la que pueden usarse **kernels** (lo veremos más adelante)^{††§§}.
- El problema dual se puede resolver usando métodos de optimización cuadrática.

^{††} Los kernels se introducen para resolver problemas que no son separables linealmente: permiten aplicar una transformación no lineal a los datos y luego calcular el producto interno en ese espacio transformado, sin necesidad de calcular explícitamente la transformación. Este proceso se conoce como el "truco del kernel".

^{§§} En la formulación dual del Lagrangiano, se pueden usar *kernels* porque la función a optimizar contiene productos internos $\langle x_i, x_j \rangle$, los cuales se pueden reemplazar por funciones de *kernel* para aplicar transformaciones no lineales y así mejorar la capacidad del modelo para ajustarse a los datos no linealmente separables.

Lagrangiano Dual (2)

- El Lagrangiano dual $L_D(\beta, \beta_0, \alpha)$ es:

$$L_D(\beta, \beta_0, \alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j} y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle$$

- También se conoce como la **Wolfe dual**.
- Se logra una solución en la que pueden usarse **kernels** (lo veremos más adelante)^{††§§}.
- El problema dual se puede resolver usando métodos de optimización cuadrática.
- Los multiplicadores de Lagrange se calculan utilizando las condiciones de **Karush-Kuhn-Tucker (KKT)**, que son condiciones necesarias para encontrar un óptimo en problemas de optimización con restricciones.

^{††} Los kernels se introducen para resolver problemas que no son separables linealmente: permiten aplicar una transformación no lineal a los datos y luego calcular el producto interno en ese espacio transformado, sin necesidad de calcular explícitamente la transformación. Este proceso se conoce como el "truco del kernel".

^{§§} En la formulación dual del Lagrangiano, se pueden usar *kernels* porque la función a optimizar contiene productos internos $\langle x_i, x_j \rangle$, los cuales se pueden reemplazar por funciones de *kernel* para aplicar transformaciones no lineales y así mejorar la capacidad del modelo para ajustarse a los datos no linealmente separables.

Condiciones de Karush-Kuhn-Tucker (KKT)

Las condiciones de KKT son necesarias para encontrar el óptimo en problemas de optimización con restricciones. Para las SVC y SVM, estas condiciones incluyen:

- **Estacionaridad** (derivadas parciales deben ser cero):

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^m \alpha_i y_i x_i = 0 \quad \Rightarrow \quad w = \sum_{i=1}^m \alpha_i y_i x_i$$

$$\frac{\partial L}{\partial b} = \sum_{i=1}^m \alpha_i y_i = 0$$

- **Complementariedad:**


$$\alpha_i [y_i (\langle w, x_i \rangle + b) - 1] = 0$$

Esto implica que $\alpha_i > 0$ solo para los puntos en el margen (vectores de soporte). Si el punto está lejos del margen, $\alpha_i = 0$.

- **No negatividad:**

$$\alpha_i \geq 0 \quad \forall i$$

i	Data point x	label t	α
0	(1,2)	+1	0.5
1	(2,1)	+1	0.5
2	(3,3)	+1	0
3	(0,0)	-1	1
4	(-1,-1)	-1	0
5	(-3,1)	-1	0



- Para el punto $i = 0$, calculamos el producto escalar $\langle w, x_0 \rangle$ y sumamos el término independiente b :

$$\langle w, x_0 \rangle + b = \frac{3}{2} \cdot (1) + \frac{3}{2} \cdot (2) - \frac{8}{3} = \frac{17}{6}$$

- Dado que $\alpha_0 = 0,5 > 0$, este valor cumple con la condición de complementariedad y este punto es un **vector de soporte**.

Inferencia para un nuevo punto

1. Ecuación del hiperplano de decisión:

$$f(x) = \frac{3}{2}x_1 + \frac{3}{2}x_2 - \frac{8}{3}$$

donde:

- $w = \left(\frac{3}{2}, \frac{3}{2}\right)$ es el vector de pesos.
- $w_0 = -\frac{8}{3}$ es el sesgo.

2. Evaluar el nuevo punto $x = (2, 2)$:

$$f(2, 2) = \frac{3}{2}(2) + \frac{3}{2}(2) - \frac{8}{3}$$


$$f(2, 2) = 6 - \frac{8}{3} = \frac{18}{3} - \frac{8}{3} = \frac{10}{3} \approx 3,33$$

3. Clasificación:

- Si $f(x) > 0$, entonces x pertenece a la clase $+1$.
- Si $f(x) < 0$, entonces x pertenece a la clase -1 .

En este caso, $f(2, 2) \approx 3,33$, por lo tanto, el punto $(2, 2)$ se clasifica en la clase $+1$.



Construction of the Maximal Margin Classifier (4)



En muchos casos no existe un hiperplano de separación, por lo que no hay máximo clasificador de margen. En este caso, el problema de optimización (9)-(11) no tiene solución con $M > 0$.



Support Vector Classifier

Support Vector Classifier



- Un clasificador basado en un hiperplano de separación clasificará necesariamente a la perfección todas las observaciones de entrenamiento; esto puede provocar sensibilidad a observaciones individuales.
- En la figura, la adición de una sola observación en el panel derecho de la figura provoca un cambio drástico en el hiperplano de margen máximo.

Support Vector Classifier2 (2)





- El hiperplano de margen máximo puede no ser satisfactorio, ya que su sensibilidad a cambios en una sola observación sugiere que puede haber sobreajuste. Además, la distancia al hiperplano, que indica la confianza en la clasificación, puede no ser fiable en estos casos.

Support Vector Classifier (3)

- **SVC puede clasificar erróneamente unas pocas observaciones de entrenamiento** con el fin de hacer un mejor trabajo en la clasificación de las observaciones restantes.
- SVC no busca el mayor margen posible para que cada observación no sólo esté en el lado correcto del hiperplano y del margen, **se permite que algunas observaciones estén en el lado incorrecto del margen o el hiperplano.**
- **El margen es suave** porque puede ser violado por algunas de las observaciones de entrenamiento.

Support Vector Classifier (4)



- **Izquierda:** Observación 1 y 8 están en el lado incorrecto del margen.
- **Derecha:** 11 y 12 están en el lado equivocado del hiperplano y en el lado equivocado del margen.

Support Vector Classification




FIGURE 12.1. Support vector classifiers. The left panel shows the separable case. The decision boundary is the solid line, while broken lines bound the shaded maximal margin of width $2C = 2/\|\beta\|$. The right panel shows the nonseparable (overlap) case. The points labeled ξ_j^* are on the wrong side of their margin by an amount $\xi_j^* = C\xi_j$; points on the correct side have $\xi_j^* = 0$. The margin is maximized subject to a total budget $\sum \xi_i \leq \text{constant}$. Hence $\sum \xi_j^*$ is the total distance of points on the wrong side of their margin.

Support Vector Classifier (5)

$$\underset{\beta_0, \beta_1, \dots, \beta_p, \xi_1, \dots, \xi_n, M}{\text{maximize}} \quad M \quad (12)$$

$$\text{subject to} \quad \sum_{j=1}^p \beta_j^2 = 1 \quad (13)$$

$$y_i (\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip}) \geq M(1 - \xi_i) \quad \forall i = 1, \dots, n \quad (14)$$

$$\xi_i \geq 0, \quad \sum_{i=1}^n \xi_i \leq C, \quad (15)$$

- donde C es un **parámetro de ajuste no negativo**. Como en (11), M es el ancho del margen; buscamos hacer esta cantidad lo más grande posible.
- En (14), $\xi_1, \dots, \xi_n$ son **variables de holgura** que permiten que las observaciones individuales estén en el lado incorrecto del margen o del hiperplano.

Support Vector Classifier (6)

$$\underset{\beta_0, \beta_1, \dots, \beta_p, \xi_1, \dots, \xi_n, M}{\text{maximize}} \quad M \quad (12)$$

$$\text{subject to} \quad \sum_{j=1}^p \beta_j^2 = 1 \quad (13)$$

$$y_i (\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip}) \geq M(1 - \xi_i) \quad \forall i = 1, \dots, n \quad (14)$$

$$\xi_i \geq 0, \quad \sum_{i=1}^n \xi_i \leq C, \quad (15)$$

- La variable de holgura ξ_i indica dónde se encuentra la i -ésima observación en relación con el hiperplano y el margen.
- Si $\xi_i = 0$, entonces la i -ésima observación está en el lado correcto del margen.
- Si $\xi_i > 0$, entonces la i -ésima observación está en el lado incorrecto del margen, y decimos que la i -ésima observación ha violado el margen.
- Si $\xi_i > 1$, entonces está en el lado incorrecto del hiperplano.





Support Vector Classifier (7)

$$\xi_i \geq 0, \quad \sum_{i=1}^n \xi_i \leq C, \quad (15)$$

- C es el limite para la cantidad en la que el margen puede ser violado por las n observaciones.
- Si $C = 0$, el problema del SVC se convierte en un problema de optimización del MMC (solo existe si las dos clases son separables).
- **A medida que C disminuye, somos menos tolerantes con las violaciones del margen, y el margen se estrecha.**
- C se trata como un parámetro de ajuste que generalmente se elige mediante validación cruzada.
- C controla el compromiso entre sesgo y varianza de la técnica de aprendizaje estadístico^{¶¶}.

^{¶¶} Si C es bajo, el modelo intenta ajustar perfectamente todos los datos de entrenamiento, incluidas las excepciones o el ruido, lo que puede llevar a un sobreajuste (alta varianza). Si C es alto, el modelo está dispuesto a permitir algunos errores de clasificación con el objetivo de mantener un margen más amplio y tener una mejor generalización, lo que reduce la varianza.

Support Vector Classifier (8)



SMO (Soft margin Optimization)

- Intenta mejorar el problema de generalización de *Hard Margin*.
- Cuyo problema de optimización es (solo optimizaciones):

$$\text{Minimizar}_{\beta, \beta_0} \langle \beta, \beta \rangle$$

$$\text{Sujeto a: } y_i(\langle \beta, x_i \rangle + \beta_0) \geq 1, \quad i = 1, \dots, m$$

- Introduciremos variables de holgura permitiendo violar las restricciones:

$$\text{Sujeto a: } y_i(\langle \beta, x_i \rangle + \beta_0) \geq 1 - \xi_i, \quad i = 1, \dots, m$$

$$\xi_i \geq 0, \quad i = 1, \dots, m$$

- De la misma forma, necesitamos controlar el tamaño de las violaciones ξ_i .

- Cuyo problema de optimización es:

$$\text{Minimizar}_{\beta, \beta_0} \langle \beta, \beta \rangle + C \sum_{i=1}^m \xi_i^2 \quad \text{S.A.} \quad \begin{cases} y_i(\langle \beta, x_i \rangle + \beta_0) \geq 1 - \xi_i, & i = 1, \dots, m \\ \xi_i \geq 0, & i = 1, \dots, m \end{cases}$$

- C controla el equilibrio entre los errores de clasificación y el margen.
- El Lagrangiano primal de este problema es:

$$L(\beta, \beta_0, \xi, \alpha) = \frac{1}{2} \langle \beta, \beta \rangle + \frac{C}{2} \sum_{i=1}^m \xi_i^2 - \sum_{i=1}^m \alpha_i [y_i(\langle \beta, x_i \rangle + \beta_0) - 1 + \xi_i]$$

- donde $\alpha_i \geq 0$ son los multiplicadores de Lagrange.

Soft Margin norma 2 (2)

- Para encontrar la forma dual debemos derivar respecto a β , ξ , y β_0

$$\frac{\partial \mathcal{L}(\beta, \beta_0, \xi, \alpha)}{\partial \beta} = \beta - \sum_{i=1}^m y_i \alpha_i x_i = 0$$

$$\frac{\partial \mathcal{L}(\beta, \beta_0, \xi, \alpha)}{\partial \xi} = C\xi - \alpha = 0$$

$$\frac{\partial \mathcal{L}(\beta, \beta_0, \xi, \alpha)}{\partial \beta_0} = \sum_{i=1}^m y_i \alpha_i = 0$$

- Reemplazando estas relaciones en el primal obtenemos la siguiente función objetivo:

$$\begin{aligned} L(\beta, \beta_0, \xi, \alpha) &= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle \\ &= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle - \frac{1}{2C} \langle \alpha, \alpha \rangle \end{aligned}$$

Sustituyendo en la Función Lagrangiana Original

1. Función Lagrangiana original:

$$L(\beta, \beta_0, \xi, \alpha) = \frac{1}{2} \langle \beta, \beta \rangle + \frac{C}{2} \sum_{i=1}^m \xi_i^2 - \sum_{i=1}^m \alpha_i [y_i (\langle \beta, x_i \rangle + \beta_0) - 1 + \xi_i]$$

2. Sustituimos $\beta = \sum_{i=1}^m \alpha_i y_i x_i$:

$$\begin{aligned} L(\alpha) &= \frac{1}{2} \left\langle \sum_{i=1}^m \alpha_i y_i x_i, \sum_{j=1}^m \alpha_j y_j x_j \right\rangle + \frac{C}{2} \sum_{i=1}^m \xi_i^2 \\ &\quad - \sum_{i=1}^m \alpha_i \left[y_i \left(\sum_{j=1}^m \alpha_j y_j \langle x_j, x_i \rangle + \beta_0 \right) - 1 + \xi_i \right] \end{aligned}$$

3. Sustituimos $\xi_i = \frac{\alpha_i}{C}$:

$$\begin{aligned} L(\alpha) &= \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle + \frac{1}{2C} \sum_{i=1}^m \alpha_i^2 \\ &\quad - \sum_{i=1}^m \alpha_i \left[y_i \sum_{j=1}^m \alpha_j y_j \langle x_j, x_i \rangle + y_i \beta_0 - 1 + \frac{\alpha_i}{C} \right] \end{aligned}$$


4. **Continuación** $\sum_{i=1}^m y_i \alpha_i = 0$:

$$L(\alpha) = \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle + \frac{1}{2C} \sum_{i=1}^m \alpha_i^2$$
$$- \left[\sum_{j=1}^m \alpha_i \alpha_j y_i y_j \langle x_j, x_i \rangle + \sum_{i=1}^m y_i \beta_0 \alpha_i - \sum_{i=1}^m \alpha_i + \sum_{i=1}^m \frac{\alpha_i \alpha_i}{C} \right]$$

5. **Simplificación:**

$$L(\alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle - \frac{1}{2C} \sum_{i=1}^m \alpha_i^2$$

¿Por qué los α_i son 0 para los no SV?



SVM: Hiperplano, márgenes y verificación de puntos

Para este ejemplo, los valores obtenidos son:


$$0,46 \cdot x_1 + 0,31 \cdot x_2 - 3,62 = 0$$

Verificación de puntos respecto al margen:

$$f(x) = 0,46 \cdot x_1 + 0,31 \cdot x_2 - 3,62$$


- Punto (1, 2): $f(1, 2) = -2,54$, No está en el margen.
- Punto (2, 3): $f(2, 3) = -1,77$, No está en el margen.
- Punto (3, 4): $f(3, 4) = -1,00$, Está en el margen inferior.
- Punto (6, 6): $f(6, 6) = 1,00$, Está en el margen superior.
- Punto (7, 8): $f(7, 8) = 2,77$, No está en el margen.
- Punto (8, 9): $f(8, 9) = 3,54$, No está en el margen.

Support Vector Machine (SVM)



SVM es una ampliación del SVC para adaptarse a límites de clase no lineales. Las SVM están pensadas para la clasificación binaria, en la que existen dos clases.

SVM (2)



- Para abordar problemas que no son separables linealmente, se puede ampliar el espacio de características utilizando términos cuadráticos, cúbicos o incluso polinomiales de mayor orden.
- Por ejemplo, en lugar de ajustar un clasificador de vectores de soporte con p características $X_1, X_2, \dots, X_p$, podemos ajustarlo con $2p$ características, utilizando términos como: $X_1, X_1^2, X_2, X_2^2, \dots, X_p, X_p^2$.

$$\underset{\beta_0, \beta_{11}, \dots, \beta_{p1}, \beta_{p2}, \xi_1, \dots, \xi_n, M}{\text{maximize}} \quad M \quad (16)$$

$$\text{subject to} \quad y_i \left(\beta_0 + \sum_{j=1}^p \beta_{j1} x_{ij} + \sum_{j=1}^p \beta_{j2} x_{ij}^2 \right) \geq M(1 - \xi_i), \quad (17)$$

$$\sum_{i=1}^n \xi_i \leq C, \quad \xi_i \geq 0, \quad \sum_{j=1}^p \sum_{k=1}^2 \beta_{jk}^2 = 1. \quad (18)$$

- ¿Por qué lleva esto a una frontera de decisión no lineal? En el espacio de características ampliado, la frontera de decisión que resulta de (16-18) es lineal.
- Podríamos querer ampliar aún más el espacio de características usando términos polinomiales de mayor orden. También se podrían considerar otras funciones de los predictores en lugar de polinomios.
- El SVC permite ampliar el espacio de características de manera que conduzca a cálculos eficientes.

The Support Vector Machine

SVM es una extensión del clasificador de soporte vectorial que resulta de ampliar el espacio de características de una manera específica, usando *kernels*.

La idea principal es que queremos ampliar nuestro espacio de características para acomodar una frontera no lineal entre las clases.

- El producto interno de dos observaciones $x_i, x_{i'}$ se define como:

$$\langle x_i, x_{i'} \rangle = \sum_{j=1}^p x_{ij} x_{i'j}. \quad (19)$$

- El clasificador de soporte vectorial lineal se puede representar como:

$$f(x) = \beta_0 + \sum_{i=1}^n \alpha_i \langle x, x_i \rangle, \quad *** \quad (20)$$

donde n corresponde a los parámetros α_i , $i = 1, \dots, n$, uno por cada observación de entrenamiento.

*** Inferencia... ¿Por qué no están β ? (Formulación dual)

The Support Vector Machine (2)

- Para estimar los parámetros $\alpha_1, \dots, \alpha_n$ y β_0 , necesitamos calcular los productos internos $\langle x_i, x_{i'} \rangle$ entre todos los pares de observaciones de entrenamiento $\binom{n}{2} = \frac{n(n-1)}{2}$.
- En la ecuación (20), para evaluar la función $f(x)$, se debe computar el producto interno entre el nuevo punto x y cada uno de los puntos de entrenamiento x_i ^{†††}.
- Sin embargo, resulta que α_i es distinto de cero sólo para los SV es decir, si una observación de entrenamiento no es un SV, entonces su $\alpha_i = 0$. Así que si S es la colección de índices de estos SV, podemos reescribir cualquier función de solución de la forma (20) como:

$$f(x) = \beta_0 + \sum_{i \in S} \alpha_i \langle x, x_i \rangle, \quad (21)$$

- El signo de $f(x)$ determina la clase a la que pertenece el punto. Específicamente:
 - Si $f(x) > 0$, el punto se clasifica en la clase $+1$.
 - Si $f(x) < 0$, el punto se clasifica en la clase -1 .

^{†††}En la solución dual se debe computar el producto interno

Cantidad de Productos Internos en SVM (Método del Kernel)

Caso 1: Todos los Pares de Puntos

- Incluye los productos internos entre **todos los puntos**, incluyendo un punto consigo mismo.
- **Número de productos internos:** $N \times N$
- **Ejemplo** (para $N = 3$):

$$\langle x_1, x_1 \rangle, \langle x_1, x_2 \rangle, \langle x_1, x_3 \rangle$$

$$\langle x_2, x_1 \rangle, \langle x_2, x_2 \rangle, \langle x_2, x_3 \rangle$$


$$\langle x_3, x_1 \rangle, \langle x_3, x_2 \rangle, \langle x_3, x_3 \rangle$$

Caso 2: Pares Distintos de Puntos

- Incluye solo los productos internos entre **pares distintos** de puntos.
- **Número de productos internos:** $\frac{N(N-1)}{2}$
- **Ejemplo** (para $N = 3$):

$$\langle x_1, x_2 \rangle, \langle x_1, x_3 \rangle, \langle x_2, x_3 \rangle$$

Kernels en SVM



- El uso de **kernels** $\Omega(\cdot)$ en SVM, consiste en agregar dimensiones adicionales de forma que los datos sean separables.
- La técnica evalúa nuevos puntos de datos según su posición respecto al hiperplano de decisión. Los puntos a un lado se asignan a una clase, y los del otro lado, a la clase opuesta,

Truco del Kernel en SVM

- Supongamos que cada vez que el producto interno (19) aparece en la representación (20), lo reemplazamos con una generalización del producto interno de la forma

$$\Omega(x_i, x_{i'}) \quad (22)$$

donde Ω es una función que denominamos *kernel*.

- Un kernel es una función que cuantifica la similitud entre dos observaciones. Por ejemplo, podríamos tomar:

$$\Omega(x_i, x_{i'}) = \sum_{j=1}^p x_{ij} x_{i'j}, \quad (23)$$

lo que nos devolvería el SVC estándar. La ecuación (23) se conoce como el *kernel lineal* porque el clasificador es lineal en las características. Este kernel lineal cuantifica la similitud de un par de observaciones utilizando la correlación de Pearson estándar.

SVM No lineales

- Gran parte de los datos en escenarios del mundo real no son linealmente separables, y es ahí donde entran en juego las SVM no lineales.
- Para hacer que los datos sean linealmente separables, se aplican métodos de preprocesamiento a los datos de entrenamiento para transformarlos a un espacio de características de mayor dimensión.

Los espacios de mayor dimensión pueden crear más complejidad al aumentar el riesgo de sobreajuste y ser computacionalmente costosos. El "truco del kernel" ayuda a reducir parte de esa complejidad, haciendo que el cálculo sea más eficiente al reemplazar el producto escalar por una función kernel equivalente.

Algunos tipos populares de funciones kernel incluyen:

- Kernel polinómico
- Kernel de base radial (también conocido como kernel gaussiano o RBF)
- Kernel sigmoide

- **Kernel Polinómico:** Mapea los datos de entrada a un espacio de características de mayor dimensión utilizando una función polinómica. El kernel polinómico se define como:


$$\Omega(x_i, x_{i'}) = \left(1 + \gamma \sum_{j=1}^p x_{ij} x_{i'j} \right)^d. \quad (24)$$

Donde γ y d son parámetros ajustables. El parámetro d controla el grado del polinomio y γ ajusta la influencia de los términos de interacción.


- El kernel polinómico es útil cuando los datos tienen una estructura polinómica y no son linealmente separables en su dimensionalidad original.
- La frontera de decisión del clasificador se ajusta a una frontera flexible, lo que es fundamental para ajustar el clasificador a límites no lineales.

Kernel Polinómico

Datos originales en 2D (No linealmente separables)



Datos transformados con kernel polinómico (grado 3)



Kernel de Base Radial (RBF)

- También conocido como Gaussian Kernel, utiliza una función de base radial para mapear los datos a un espacio de características de dimensión infinita. El kernel RBF se define como:

$$\Omega(x_i, x_{i'}) = \exp \left(-\gamma \sum_{j=1}^p (x_{ij} - x_{i'j})^2 \right) \quad (24)$$



Donde γ es un parámetro ajustable que controla la influencia del término exponencial. El kernel RBF es efectivo para datos no linealmente separables y es capaz de capturar patrones complejos en los datos.

- `sklearn.svm.SVC` usa RBF como kernel por defecto, y su parámetro γ está definido por la operación *scale*:

$$\gamma = \frac{1}{(n_{\text{features}} \cdot \sigma^2(X))}$$


La escala consiste en dividir por el número de atributos multiplicado por la varianza de los datos sobre los mismos atributos.

Kernel de Base Radial (RBF)



En la derecha, la superficie representa el valor de la función de decisión del modelo SVM para cada punto en el espacio 2D transformado.

Ejemplo de SVM con kernel polinómico y RBF



- **Izquierda:** Se aplica una SVM con un núcleo polinómico de grado 3 a los datos no lineales.
- **Derecha:** Se aplica una SVM con un núcleo radial. En este ejemplo, cualquiera de los dos kernel es capaz de capturar el límite de decisión.

- Para esto se utiliza una función kernel $\Omega(\mathbf{x}_i, \mathbf{X}_t)$ que traslada los vectores originales de entrada $\mathbf{X}_t$ a un espacio de alta dimensión para asegurar su separabilidad lineal a través de estos hiperplanos.
- Encontrar el hiperplano óptimo que separa dos clases es equivalente a resolver el problema de optimización descrito en la siguiente expresión:

$$\mathbf{y} = \sum_{i=1}^N \mathbf{w}_i \Omega(\mathbf{x}_i, \mathbf{X}_t) + \mathbf{b} \quad (1)$$

- En que $\mathbf{y}$ es el resultado de la clasificación, $\mathbf{w}_i$ es el peso i -ésimo adaptado al modelo, $\mathbf{x}_i$ es el vector de soporte i -ésimo y $\mathbf{b}$ es el bias o sesgo del hiperplano con respecto al origen.

- En general, el objetivo es calcular los valores de la matriz de pesos $\mathbf{w}^*$ que cumplan con (2).

$$(\mathbf{w}^*, \mathbf{b}) =_{w,b,\xi} \frac{1}{2} |\mathbf{w}^*|^2 + \mathbf{C} \sum_{i=1}^S \xi_i \quad (2)$$

$$\mathbf{y}_i(\mathbf{w}^* \mathbf{x}_i + \mathbf{b}) \geq 1 - \xi_i \quad , \quad \xi_i \geq 0 \quad (3)$$

- Donde S hace referencia al número de kernels y $\mathbf{C}$ es un parámetro de penalización elegido durante el entrenamiento.
- La ecuación (2) está sujeta a la restricción (3), debido a que dentro del problema de optimización se introducen **variables de holgura** cuando los datos no son reparables para permitir violar las restricciones^{†††}. ξ_i es el vector de holgura que hace referencia al tamaño de dichas violaciones.

^{†††}Chapelle, O., Haffner, P., Vapnik, V. N. (1999). Support vector machines for histogram-based image classification. IEEE transactions on Neural Networks, 10(5), 1055-1064.

Gracias!