



UNIVERSIDAD TÉCNICA
FEDERICO SANTA MARÍA

Introduction to Data Science


EIN087B - Ciencia de Datos

Profesor: Jorge Portilla G.
jorge.portilla@usm.cl

Departamento de Electrónica e Informática
Universidad Técnica Federico Santa María
Concepción, Chile



Seaborn - sns.pairplot



Histograma de una imagen:

$$h(k) = n_k$$

con $k \in \{0, \dots, L\}$ nivel de gris (para L niveles de gris), y n_k el número de píxeles de la imagen con valor de nivel de gris k .

- Es común también utilizar la versión normalizada del histograma en $[0; 1]$:


$$p(k) = \frac{n_k}{n}$$

con n como el número total de píxeles en la imagen.


- Se puede decir que $p(k)$ es un estimador de la probabilidad de ocurrencia del nivel de gris k en la imagen.
- Histogramas son herramientas importantes para segmentación de imágenes en tiempo real (simples y de bajo costo computacional).

Histograma 2D

Imagen Original



Histogramas RGB



Histogramas RGB (Escala Log)







Imagen en Escala de Grises



Histograma en Escala de Grises



Histograma en Escala de Grises (Log)




Revisar enlace <https://docs.baslerweb.com/histogram>

Cross-Industry Standard Process for Data Mining (CRISP-DM)

¿Qué es Data Science?

Data Science es el uso de métodos estadísticos y matemáticos para identificar un problema, luego encontrar, organizar y analizar datos para buscar patrones que puedan llevar a soluciones¹.



Data Science integra métodos científicos de la estadística, la informática y el dominio de aplicación, dependiendo del problema que se esté resolviendo.

¹.An Introduction to Data Science Projects, Prof. Dr. Tim Kacprowski, Prof. Dr. Wolf-Tilo Balke, April 17, 2023"

The ability to take data — to be able to understand it, to process it, to extract value from it, to visualize it, to communicate it — that's going to be a hugely important skill in the next decades.

"La capacidad de tomar datos, comprenderlos, procesarlos, extraer valor, visualizarlos y comunicarlos será una habilidad de suma importancia en las próximas décadas."

Hal Varian,
chief economist at Google and UC Berkeley professor of information sciences, business, and economics

► **Matemáticas y estadística**

- Análisis y capacidad de seleccionar un tipo de técnicas computacional.

► **Manipulación de datos**

- Limpieza y organización de los datos

► **Habilidades de programación**

► **Conocimiento del dominio**

- Conocimiento de los conceptos subyacentes relevantes para optimizar y adaptar el trabajo técnico a los requisitos únicos del proyecto.

► **Habilidades de comunicación**

- Interacción con expertos e investigadores.

► **Matemáticas y estadística**

- Análisis y capacidad de seleccionar un tipo de técnicas computacional.

► **Manipulación de datos**

- Limpieza y organización de los datos

► **Habilidades de programación**


► **Conocimiento del dominio**


- Conocimiento de los conceptos subyacentes relevantes para optimizar y adaptar el trabajo técnico a los requisitos únicos del proyecto.

► **Habilidades de comunicación**

- Interacción con expertos e investigadores.

Estas habilidades son requeridas en la mayoría de industrias, y los científicos de datos se hacen cada vez más valiosos para las empresas...






Key steps in a data science process²

²Xiaogang Ma., et al., Using Visual Exploratory Data Analysis to Facilitate Collaboration and Hypothesis Generation in Cross-Disciplinary Research, "ISPRS Int. J. Geo-Inf. 2017, 6(11),


1. Definir el alcance al proyecto



- ¿Cuáles son los principales problemas que se buscan resolver?
- ¿Cuál es la variable objetivo o el resultado que se debe predecir?
- ¿Qué estrategia se utilizará para lograrlo?

1. Definir el alcance al proyecto: Ejemplo


- ▶ **Título:** Proyecto sobre detección de neumonía en radiografías de tórax.
- ▶ **Objetivo:** Diagnóstico temprano de neumonía para asistir a los radiólogos.
- ▶ **Métodos:** Modelo de aprendizaje profundo basado en redes neuronales convolucionales (CNN).
- ▶ **Salida:** Probabilidad de presencia de neumonía en una radiografía dada.



2. Data Understanding

- ▶ La Ciencia de Datos es **multidisciplinaria**.
- ▶ Familiarizarse con el conocimiento relevante del dominio específico.
- ▶ Comprende los conceptos básicos
- ▶ Comunicación con colaboradores
 - → ¿De dónde provienen los datos? ¿Qué significan? ¿Cuáles son los posibles problemas o desafíos con los datos? ¿Como evaluó los resultados? ¿Cual es el groundtruth?

2. Data Understanding



¹Imagen tomada de <https://liiscience.org/meeting/past-meetings/2005-lii-workshop/m2005s9>

- ▶ La pirometría de hollín se usa para estimar temperaturas en llamas mediante imágenes de emisión térmica.
- ▶ El hollín emite radiación térmica que puede analizarse mediante cámaras en diferentes longitudes de onda.
- ▶ **Datos:** Imágenes capturadas en llamas laminares con diferentes niveles de emisión de hollín.
- ▶ Diagnósticos ópticos costosos y requiere resolver problemas inversos altamente sensibles al ruido.
- ▶ ¿Se puede mejorar la estimación de temperatura considerando la absorción del hollín y otros efectos ópticos?

3. Data Collection

- **Recopilar los datos necesarios para el proyecto**

- ▶ **Ejemplos:**

- **Datos clínicos:**

- Historial médico del paciente.
 - Síntomas y signos clínicos .
 - Resultados de exámenes físicos

- **Imágenes médicas:**

- Radiografías de tórax (RX).
 - Tomografías computarizadas (TC) de tórax.
 - Resonancias magnéticas (RM) de tórax (en casos específicos).

- **Datos microbiológicos:**

- Pruebas de PCR para detección de patógenos respiratorios.


- **Datos epidemiológicos:**

- Edad, sexo, comorbilidades del paciente.
 - Exposición a factores de riesgo (tabaquismo, exposición a contaminantes).
 - Datos de brotes epidémicos.

4. Data Preparation

- ▶ Los datos brutos (raw data) deben limpiarse y preprocesarse antes de usarse:
 - Manejo de valores faltantes
 - Duplicados
 - Imputación
 - Eliminar datos de baja calidad
 - Eliminar valores atípicos
 - Formateo
 - Normalización de datos inconsistentes
 - (Ingeniería de características)
- ▶ El **Análisis Exploratorio de Datos** puede ayudar a identificar la estructura, los valores atípicos, las anomalías y los patrones presentes en los datos.

4. Preparación de Datos: Ejemplo



4.1. Análisis exploratorio de datos

Datos con valores faltantes → Imputación (media)

ID	Variable A	Variable B
0	0.05	2.0
1	NaN	3.3
2	0.72	NaN
3	0.25	1.7
4	NaN	4.0
5	0.42	NaN
6	0.39	2.7
7	0.59	2.0
8	0.10	1.3

→


ID	Variable A	Variable B
0	0.05	2.0
1	0.36	3.3
2	0.72	2.4
3	0.25	1.7
4	0.36	4.0
5	0.42	2.4
6	0.39	2.7
7	0.59	2.0
8	0.10	1.3

Núcleo de un Proyecto de Ciencia de Datos

- ▶ Núcleo de un proyecto de ciencia de datos
- ▶ Encontrar patrones en los datos
- ▶ ¿Qué algoritmos de *machine learning* son adecuados para el proyecto?
 - Regresión lineal
 - Random Forest
 - Máquinas de vectores de soporte
 - *Deep learning*
 - Métodos de agrupación
 - Otros métodos computacionales emergentes

5. Analisis de Datos y Modelado


- Construir un modelo capaz de predecir una variable de interés.
- Entrenar el modelo usando data preprocesada de las etapas anteriores.



³<https://towardsdatascience.com/workflow-of-a-machine-learning-project-ec1dba419b94>

6. Evaluación del modelo

- ▶ ¿Son los resultados realmente válidos?
 - ▶ ¿Son los hallazgos robustos y reproducibles?
 - ▶ Para modelos de aprendizaje automático: ¿generaliza bien el modelo?
-
- ▶ Métricas clave (precisión, recall, RMSE).
 - ▶ Comparación entre modelos. **Se espera que el modelo generalice y no sobreajuste.**



7. Interpretación

- ▶ ¿Qué sentido tienen los resultados?
- ▶ ¿Qué conclusiones pueden extraerse de los resultados?

7. Interpretación

- ▶ ¿Qué sentido tienen los resultados?
 - ▶ ¿Qué conclusiones pueden extraerse de los resultados?
-

- ▶ Para el ejemplo de Pirometría de hollín (slide 21), comparaciones con métodos ópticos más sofisticados pueden validar la fiabilidad del modelo basado en imágenes de color.
- ▶ Los resultados pueden contribuir a mejorar modelos de combustión y optimizar procesos industriales donde la formación de hollín es crítica.

8. Publishing and Presentation

- ▶ «Narración de datos»
- ▶ Resume los resultados para facilitar su comprensión
- ▶ Visualizar los resultados
- ▶ Comunique sus resultados a sus colegas, a la comunidad científica y a un público más amplio.
 - Diseñar figuras y carteles significativos
 - Publicar un artículo sobre sus hallazgos en una revista de investigación científica.
 - Asistir a una conferencia y presentar su trabajo.



Introduction to Machine Learning models

The Curse of Dimensionality




4

- ▶ *Curse of dimensionality* surge cuando se analizan datos en espacios de alta dimensión.
- ▶ En la derecha, una variable con 10 regiones de interés. Con suficientes ejemplos los [algoritmos de aprendizaje](#) pueden generalizar correctamente.
- ▶ Se requieren exponencialmente más datos para cubrir todas las posibles configuraciones (datos dispersos dificulta la generalización).


⁴Goodfellow, I., Bengio, Y., Courville, A. (2016). Deep Learning. MIT Press.

The Curse of Dimensionality - examples



The Curse of Dimensionality - examples

"Words (in 2D) by Joseph on features learned by Ronan and Jason" representa palabras proyectadas en 2D desde un espacio de alta dimensionalidad. Estas características fueron aprendidas mediante modelos de embeddings de palabras, capturando relaciones semánticas y sintácticas en un corpus de texto. La visualización ilustra cómo palabras con significados similares tienden a agruparse, reflejando la estructura latente del lenguaje. <https://lvdmaaten.github.io/tsne/>



The Curse of Dimensionality - examples




The Curse of Dimensionality - examples


"Netflix dataset (in 3D) on Russ's RBM features" representa datos de calificaciones de usuarios proyectados en un espacio tridimensional.

Las características fueron extraídas mediante una Restricted Boltzmann Machine (RBM) entrenada por Russ Salakhutdinov, capturando patrones latentes en las preferencias de los usuarios. La visualización muestra cómo las películas y usuarios se organizan en función de sus relaciones implícitas, destacando la estructura del dataset de recomendaciones.

<https://lvdmaaten.github.io/tsne/>





The Curse of Dimensionality - examples



The Curse of Dimensionality - examples

"20 Newsgroups dataset (in 2D) on Simon's discLDA features" muestra la proyección de temas de discusión en un espacio bidimensional. Las características fueron extraídas con discLDA, capturando patrones latentes en los textos y organizando documentos según su contenido.





5

Capacidad que exhiben las **herramientas** para realizar tareas que requieren **inteligencia**.

- Independiente de los componentes, aplicación, razonamiento, etc.

⁵<https://k21academy.com/datascience-blog/deep-learning/dl-vs-ml/>

¿Qué es aprendizaje automático?

"A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P , its performance at tasks in T , as measured by P , improves with experience E ."

— *Tom Mitchell*

Arthur Samuel

"Machine learning is the field of study that gives computers the ability to learn without being explicitly programmed"

Machine Learning (ML) es el campo científico que estudia los algoritmos que permiten a los ordenadores mejorar su rendimiento en una tarea específica mediante un proceso de aprendizaje iterativo en lugar de mediante reglas programadas explícitamente.

Algorithm 1 Identificar si es un perro o no

```
1: procedure IdentificarPerro(imagen)
2:   if imagen tiene características de perro then
3:     Return "Es un perro"
4:   else
5:     Return "No es un perro"
6:   end if
7: end procedure
```

Chihuahua or muffin?







< Back labradoodle or fried chicken Select



< Albums sheepdog or mop Select



< Albums puppy or bagel Select



< Albums shiba or marshmallow Select



- Supongamos que tenemos un conjunto de datos que da el peso, el sexo y las calorías al día de 40 personas.

Peso (kg)	Sexo	Calorías al día
70	Masculino	2500
55	Femenino	2000
65	Masculino	2200
$\vdots$	$\vdots$	$\vdots$

- Nos gustaría predecir el consumo de calorías al día de otras personas.
- En este caso, el peso y el género se llaman **input features**. Cada **vector input** x_m tiene estas dos características.
- El consumo de calorías por día y_m se denomina **target**.
- Un par (x_m, y_m) es un ejemplo de entrenamiento. Un **train set** es un grupo de M ejemplos de entrenamiento $S_M = \{(x_m, y_m)\}, m = 1, \dots, M$.

- Features pueden ser **numerical** o **categorical**.
- Sea $\mathcal{X}$ el espacio de características (**feature space**), y $\mathcal{Y}$ el espacio de salida (**output space**).
- Nuestro objetivo es obtener un mapeo $f : \mathcal{X} \rightarrow \mathcal{Y}$, comúnmente llamado hipótesis o aprendiz, donde $\mathcal{X} \subseteq \mathbb{R}^n$ y $\mathcal{Y} \subseteq \mathbb{R}$.
- Sea S el espacio que abarca las muestras posibles, extraídas de una distribución desconocida $P(\mathbf{x}, y)$.
- Un algoritmo de aprendizaje es un mapa desde el espacio de conjuntos de entrenamiento al espacio de hipótesis $\mathcal{H}$ de posibles soluciones funcionales.

$$A : S \rightarrow \mathcal{H}$$

Para un conjunto de entrenamiento específico S_M , el algoritmo produce una hipótesis f tal que:

$$A(S_M) = f.$$

Podemos proporcionar una descripción genérica de un algoritmo ML de la siguiente manera:


- ▶ Dado un espacio de hipótesis $\mathcal{H}$ definido por el modelo ML y sus parámetros, un conjunto de ejemplos $\mathbf{x}^{(i)} \in T$ para $i = 1, \dots, S$ que alimentar al modelo para su entrenamiento.
- ▶ Donde $T = \{(\mathbf{x}^{(1)}, \mathbf{y}^{(1)}), \dots, (\mathbf{x}^{(S)}, \mathbf{y}^{(S)})\}$ of S es un set de entrenamiento.
- ▶ **Función de coste** $\mathcal{J}(\mathbf{h}(\mathbf{x}^{(i)}))$ que cuantifica la calidad de la elección de una hipótesis $\mathbf{h} \in \mathcal{H}$ para un ejemplo $\mathbf{x}^{(i)}$.

- ▶ El objetivo general de un algoritmo ML es encontrar una hipótesis óptima $\mathbf{h}^*$ tal que

$$\mathbf{h}^* = \arg \min_{\mathbf{h} \in \mathcal{H}} \frac{1}{S} \sum_{i=1}^S \mathcal{J}(\mathbf{h}(\mathbf{x}^{(i)})). \quad (1)$$



- ▶ Si el **target** es continuo, tenemos un problema de regresión.
- ▶ Si el **target** puede tomar un número finito k de valores discretos, entonces se tiene un problema de clasificación. Si $k = 2$ el problema es llamada como clasificación binaria.



- ▶ Si el **target** es continuo, tenemos un problema de regresión.
- ▶ Si el **target** puede tomar un número finito k de valores discretos, entonces se tiene un problema de clasificación. Si $k = 2$ el problema es llamada como clasificación binaria.

- ▶ Uno de los principales retos es construir un método o algoritmo automático capaz de estimar ejemplos futuros basándose en el fenómeno observado observado en el conjunto de entrenamiento.
- ▶ Esta propiedad clave de un algoritmo se conoce como **capacidad de generalización**.
- ▶ Los algoritmos que memorizan las muestras del train set pero tienen un pobre desempeño con ejemplos desconocidos, presentan un problema que se conoce como **overfitting**⁶.

⁶Lo estudiaremos en detalles en las próximas sesiones.

Essentially, all models are wrong, but some are useful."George Box, 1987

► Predicción de Y :

- Cuando los valores de X están disponibles pero no los de Y , se puede predecir Y utilizando $\hat{f}(X)$.
- $\hat{f}$ es tratado como una caja negra en muchos casos, siempre que proporcione predicciones precisas.

Porque estimar f ?

► Predicción de Y :

- Cuando los valores de X están disponibles pero no los de Y , se puede predecir Y utilizando $\hat{f}(X)$.
- $\hat{f}$ es tratado como una caja negra en muchos casos, siempre que proporcione predicciones precisas.

► Ejemplo:

- Predicción del riesgo de una reacción adversa a un medicamento basado en características de una muestra de sangre del paciente.

► Exactitud de $\hat{Y}$:

- Depende de dos tipos de error: error reducible y error irreducible.
- El error reducible puede disminuirse mejorando $\hat{f}$.
- El error irreducible no puede eliminarse porque incluye la variabilidad inherente de ϵ .

► Ecuación del Error:

$$E(Y - \hat{Y})^2 = [f(X) - \hat{f}(X)]^2 + \text{Var}(\epsilon) \quad (2)$$

- El primer término es el error reducible.
- El segundo término es el error irreducible.

- El objetivo es encontrar una función $\hat{f}$ tal que $Y \approx \hat{f}(X)$ para cualquier observación (X, Y) .
- En términos generales, la mayoría de los métodos de aprendizaje estadístico se pueden caracterizar como *paramétricos o no paramétricos*.

- ▶ Un modelo paramétrico implica asumir una forma funcional específica para la relación entre las variables predictoras y la respuesta.

- ▶ **Asunción de la Forma Funcional:**

- Por ejemplo, una suposición simple es que f es lineal en X :

$$f(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p.$$

- ▶ **Ajuste del Modelo:**

- Después de seleccionar un modelo, se ajusta utilizando los datos de entrenamiento para estimar los parámetros $\beta_0, \beta_1, \dots, \beta_p$.
 - El método más común para ajustar el modelo lineal es los mínimos cuadrados ordinarios.

- ▶ **Ventajas:**

- Simplificación del problema de estimación - Eficiencia computacional.

- ▶ **Desventajas:**

- Riesgo de mala especificación del modelo.

- ▶ Los métodos no paramétricos no hacen suposiciones explícitas sobre la forma funcional de f .
- ▶ Buscan una estimación de f que se acerque lo más posible a los puntos de datos.
- ▶ **Ventajas:**
 - Flexibilidad para ajustarse a una amplia variedad de formas de f .
- ▶ **Desventajas:**
 - Pueden capturar patrones complejos y no lineales en los datos.
- ▶ **Ejemplo:**
 - K-Nearest Neighbors (K-NN), SVM con kernels no lineales, Árboles de decisión, etc.

El equilibrio entre la precisión de la predicción y la interpretabilidad del modelo



En general, a medida que aumenta la flexibilidad de un método, su interpretabilidad disminuye.

- ▶ Los métodos menos flexibles sólo pueden producir una gama pequeña de formas para estimar f .
 - Ejemplo: La regresión lineal es inflexible porque sólo puede generar funciones lineales.
- ▶ Los métodos más flexibles pueden generar una gama más amplia de formas para estimar f .
 - Los métodos no lineales, como bagging, boosting, support vector machines (SVM) con kernels no lineales y las redes neuronales (*deep learning*) son enfoques muy flexibles que resultan más difíciles de interpretar.

¿Por qué Utilizar Métodos Más Restrictivos?

- ▶ Los métodos restrictivos son más interpretables.
- ▶ Si el objetivo es la inferencia, los modelos restrictivos son preferibles.
 - Ejemplo: Un modelo lineal es fácil de entender en términos de la relación entre Y y los predictores $X_1, X_2, \dots, X_p$.
- ▶ Los métodos flexibles pueden hacer difícil comprender la asociación de cada predictor individual con la respuesta.

Entender la relación entre las variables independientes (predictoras) y la variable dependiente (respuesta).

- ▶ Enfoque en la interpretación de los coeficientes y la significancia estadística.
- ▶ Ejemplo: En un estudio médico, entender cómo factores como la dieta, el ejercicio y la edad influyen en la presión arterial.
- ▶ Modelos Preferidos: Modelos lineales (e.g., regresión lineal).

Ventaja: Alta interpretabilidad. Desventaja: Baja flexibilidad.

Predecir los valores futuros o desconocidos de la variable dependiente utilizando las variables independientes.

- ▶ Enfoque en la precisión de las predicciones.
- ▶ Ejemplo: En un sistema de recomendación de productos, predecir qué productos comprará un cliente basado en su historial de compras.
- ▶ Modelos Preferidos: Modelos flexibles (e.g., árboles de decisión, bosques aleatorios, redes neuronales).

Alta flexibilidad y precisión. Baja interpretabilidad.

► Aprendizaje Supervisado

- Objetivo: Predecir una respuesta específica (etiquetada) basada en datos de entrada.
- Requiere un conjunto de datos de entrenamiento con respuestas conocidas.
- Ejemplos de problemas: Clasificación y regresión.
- Ejemplos de algoritmos: Regresión lineal, regresión logística, árboles de decisión, redes neuronales.

► Aprendizaje Supervisado

- Objetivo: Predecir una respuesta específica (etiquetada) basada en datos de entrada.
- Requiere un conjunto de datos de entrenamiento con respuestas conocidas.
- Ejemplos de problemas: Clasificación y regresión.
- Ejemplos de algoritmos: Regresión lineal, regresión logística, árboles de decisión, redes neuronales.

► Aprendizaje No Supervisado

- Objetivo: Encontrar patrones o estructuras ocultas en datos no etiquetados.
- No requiere respuestas conocidas en el conjunto de datos.
- Ejemplos de problemas: Agrupamiento (clustering) y reducción de dimensionalidad.
- Ejemplos de algoritmos: K-means, análisis de componentes principales (PCA), entre otros.

► Variables Cuantitativas (Regresión)

- Toman valores numéricos.
- Ejemplos: edad, altura, ingreso, valor de una casa, precio de una acción.
- Problemas de regresión: El objetivo es predecir un valor numérico.
 - Ejemplo: Regresión lineal.

► Variables Cualitativas (Clasificación)

- Toman valores en una de K diferentes clases o categorías.
- Ejemplos: estado civil (casado o no), marca de producto (A, B, o C), diagnóstico de cáncer, entre otros.
- Problemas de clasificación: El objetivo es predecir una categoría.
 - Ejemplo: Regresión logística.

En un marco de aprendizaje supervisado, el modelo de ML adapta un conjunto de parámetros internos utilizando **pares de entrada-salida etiquetados** para obtener una función de mapeo o hipótesis $\mathbf{h}$.

- ▶ Dado un conjunto de entrenamiento $T = (\mathbf{x}^{(1)}, \mathbf{y}^{(1)}), \dots, (\mathbf{x}^{(S)}, \mathbf{y}^{(S)})$ de S vectores de entrada $\mathbf{x}^{(i)}$ y sus correspondientes salidas $\mathbf{y}^{(i)}$.
- ▶ Considerando un conjunto de parámetros $\boldsymbol{\theta}$ derivado de la arquitectura del modelo para caracterizar el espacio de funciones de mapeo $\mathbf{h}(\mathbf{x}; \boldsymbol{\theta}) \in \mathcal{H}$
- ▶ El objetivo general de un algoritmo de aprendizaje supervisado es encontrar un conjunto de parámetros $\boldsymbol{\theta}^*$ que generen un buen predictor de manera que

$$\boldsymbol{\theta}^* \approx \arg \min_{\mathbf{h}(\mathbf{x}; \boldsymbol{\theta}) \in \mathcal{H}} \frac{1}{S} \sum_{i=1}^S \mathcal{J}(\mathbf{h}(\mathbf{x}^{(i)}; \boldsymbol{\theta}), \mathbf{y}^{(i)}), \quad (3)$$

► Selección de Métodos

- Para respuesta cuantitativa, se utilizan métodos de regresión.
- Para respuesta cualitativa, se utilizan métodos de clasificación.
- Algunos métodos pueden aplicarse a ambos tipos de respuestas (e.g., K-nearest neighbors, boosting).

► Tipo de Predictores


- Generalmente, el tipo de predictores (cuantitativos o cualitativos) es menos importante.
- La mayoría de los métodos de aprendizaje estadístico pueden aplicarse independientemente del tipo de predictores, siempre que los predictores cualitativos se codifiquen adecuadamente⁷.

⁷one-hot encoding

- ▶ El desafío principal es construir un algoritmo de aprendizaje capaz de **extrapolar**.
- ▶ Es decir, estimar ejemplos futuros basados en el fenómeno observado en el conjunto de entrenamiento (**error de generalización**).
- ▶ Esta propiedad clave de un algoritmo se conoce como **capacidad de generalización**.
- ▶ Por otro lado, encontramos algoritmos que memorizan las muestras de entrenamiento pero tienen un rendimiento predictivo pobre con ejemplos desconocidos; este problema es conocido como **sobreajuste** (overfitting).


La relación entre sesgo y varianza

- ▶ El desafío principal es construir un algoritmo de aprendizaje capaz de **extrapolar**.
- ▶ Es decir, estimar ejemplos futuros basados en el fenómeno observado en el conjunto de entrenamiento (**error de generalización**).
- ▶ Esta propiedad clave de un algoritmo se conoce como **capacidad de generalización**.
- ▶ Por otro lado, encontramos algoritmos que memorizan las muestras de entrenamiento pero tienen un rendimiento predictivo pobre con ejemplos desconocidos; este problema es conocido como **sobreajuste** (overfitting).
- ▶ Si calculamos un modelo diferente para cada muestra de entrenamiento que hemos recolectado;
 - El **sesgo** es el conjunto de puntos que no pueden ser bien predichos por el modelo.
 - La **varianza** mide cuán diferentes son las predicciones a lo largo de las muestras de entrenamiento.



- ▶ Desde el punto de vista del aprendizaje automático, este compromiso está fuertemente relacionado con la complejidad del modelo f .
- ▶ Un modelo con baja complejidad tiene un alto sesgo al cubrir los puntos de entrenamiento, lo que puede llevar a un **subajuste (underfitting)**.
- ▶ Sin embargo, si la complejidad del modelo es demasiado alta, la predicción tiende a ser más cercana (menor sesgo) a los datos de entrenamiento y, en consecuencia, genera **sobreajuste**.

Sesgo y varianza trade-off



8

- ▶ En la izquierda de la gráfica, tanto el error de entrenamiento como el error de generalización son altos, lo que indica un régimen de **subajuste**.
- ▶ A medida que aumentamos la capacidad, el error de entrenamiento disminuye, pero la brecha entre el error de entrenamiento y el error de generalización (la brecha de generalización) aumenta.
- ▶ Eventualmente, el tamaño de esta brecha supera la disminución del error de entrenamiento, llevando al régimen de **sobreajuste**.
- ▶ La **capacidad óptima** es el punto donde se minimiza el error de generalización.
- ▶ Alta varianza, ante pequeñas variaciones en los datos de entrenamiento conduce a un modelo completamente diferente.

⁸Goodfellow, I., Bengio, Y., Courville, A. (2016). Deep Learning. MIT Press.



UNIVERSIDAD TÉCNICA
FEDERICO SANTA MARÍA

Introduction to Data Science

EIN087B - Ciencia de Datos

Profesor: Jorge Portilla G.
`jorge.portilla@usm.cl`

Departamento de Electrónica e Informática
Universidad Técnica Federico Santa María
Concepción, Chile