



UNIVERSIDAD TÉCNICA
FEDERICO SANTA MARÍA

Métricas de Evaluación

EIN087B - Ciencia de Datos
Paralelo 701

Profesor: Jorge Portilla G.
`jorge.portilla@usm.cl`

Departamento de Electrónica e Informática
Universidad Técnica Federico Santa María
Concepción, Chile

- 1 Métricas de evaluación
 - Problema de Regresión

- 2 Técnicas de evaluación de algoritmos de clasificación
 - Curva ROC
 - GridSearchCV
 - Métricas de evaluación para problemas de segmentación

- ▶ Least absolute shrinkage and selection operator.
- ▶ Solución sparse, encontramos los mejores descriptores para resolver el problema. Modelo interpretable.
- ▶ Coeficientes con valor cero.

- Se define el estimador **lasso** como:

$$\hat{\beta}_{\text{lasso}} = \arg \min_{\beta} \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2$$

sujeto a



$$\sum_{j=1}^p |\beta_j| \leq s$$

- Penalización L_1 ¹².
- Alternativamente,

$$\hat{\beta}_{\text{lasso}} = \argmin_{\beta} \left\{ \frac{1}{2n} \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \alpha \sum_{j=1}^p |\beta_j| \right\}$$

¹<https://www.cvxpy.org/>, SciPy (optimize), Pyomo, Quadprog, entre otros.

²La norma L_1 se calcula simplemente como la suma del valor absoluto de los elementos del vector.



Validación cruzada con conjunto de prueba (Hold-out)

- ▶ A diferencia de la validación cruzada k-fold, donde el conjunto de datos se divide en k subconjuntos y el proceso de entrenamiento y prueba se repite k veces, en el método Hold-out se realiza una sola división.
- ▶ Esto lo hace menos costoso computacionalmente, pero también más susceptible a divisiones desfavorables del conjunto de datos.
- ▶ Apropiado cuando se tiene un conjunto de datos grande y se busca una evaluación rápida del modelo, aunque para conjuntos de datos pequeños, se recomienda la validación cruzada k-fold.

Algoritmo: Validación cruzada con conjunto de prueba

1. Dividir aleatoriamente S en S_{train} (por ejemplo, el 75 % de los datos) y S_{cv} (el 25 % restante). Donde S_{cv} es el conjunto de validación cruzada.
2. Entrenar cada modelo M_i en S_{train} solo para obtener la hipótesis f_i .
3. Seleccionar y mostrar la hipótesis f_i con el menor error $\hat{\text{error}}_{S_{\text{cv}}}(f_i)$ en el conjunto de validación cruzada.

Validación cruzada con conjunto de prueba (Hold-out)

Algoritmo: Validación cruzada con conjunto de prueba

1. Dividir aleatoriamente S en S_{train} (por ejemplo, el 75 % de los datos) y S_{cv} (el 25 % restante). Donde S_{cv} es el conjunto de validación cruzada.
2. Entrenar cada modelo M_i en S_{train} solo para obtener la hipótesis f_i .
3. Seleccionar y mostrar la hipótesis f_i con el menor error $\hat{\text{error}}_{S_{\text{cv}}}(f_i)$ en el conjunto de validación cruzada.


- ▶ Así, para cada f_i obtenemos una mejor estimación del error de generalización.
- ▶ Y podemos seleccionar la hipótesis con el error de generalización estimado mínimo.
- ▶ Usualmente, el tamaño del conjunto de validación cruzada se establece entre 1/4 y 1/3.
- ▶ Estamos perdiendo datos que no estamos usando para el entrenamiento. Y estimamos el error de generalización solo a partir de un conjunto de validación cruzada.

Algoritmo: Validación Cruzada K-Fold

1. Dividir aleatoriamente S en K subconjuntos de M/K ejemplos de entrenamiento cada uno. Llamemos a estos subconjuntos $S_1, \dots, S_K$.
2. Para cada modelo M_i hacer:
 - 1) Para $j = 1, \dots, K$ hacer:
 - 1) $f_{ij} \leftarrow A_i(S \setminus S_j)$ (entrenar con todos los datos excepto S_j)
 - 2) $\hat{S}_j(f_{ij}) = \frac{1}{|S_j|} \sum_{(x_m, y_m) \in S_j} \ell(y_m, f_{ij}(x_m))$ (calcular el error sobre el conjunto de validación)
 - 2) $\hat{M}_i = \frac{1}{K} \sum_{k=1}^K \hat{S}_k(f_{ik})$ (calcular el promedio del error de validación sobre los k pliegues)
3. Seleccionar el modelo M_i con el menor $\hat{M}_i$.
4. $f \leftarrow A_i(S)$ (entrenar una hipótesis con todos los datos según el modelo M_i).
5. Salida: f

► A_i es el algoritmo de aprendizaje según el modelo M_i .

k-fold cross validation



Métricas de evaluación

- El **Error Cuadrático Medio (MSE)** mide el promedio de los errores al cuadrado entre los valores observados (y_i) y los valores predichos ($\hat{y}_i$).

Ecuación del MSE

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (1)$$

- El **Coefficiente de Determinación (R^2)** indica la proporción de la varianza en la variable dependiente que es predecible a partir de las variables independientes.
- Un R^2 cercano a 1 indica que el modelo explica bien la variabilidad de los datos.

Ecuación del R^2

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (2)$$

- El **Mean Absolute Error (MAE)** mide el promedio de los errores absolutos entre los valores observados (y_i) y los valores predichos ($\hat{y}_i$).

MAE

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3)$$

- La **Root Mean Square Error (RMSE)** es la raíz cuadrada del MSE y penaliza más fuertemente los errores grandes.
- Una RMSE más baja también indica un mejor desempeño del modelo.

RMSE

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (4)$$


Técnicas de evaluación de algoritmos de clasificación

Ground-truth

Información pre-definida que representa el resultado esperado para la resolución de cierto problema.

- ▶ Esta información se utiliza como base de comparación cuando se evalúan algoritmos para la resolución del mismo problema.
- ▶ En imágenes y video, cuando se mide la habilidad de cierto algoritmo para enfrentar cierto problema, en general, se utilizan métricas que puedan mostrar:
 - **Un valor definido** (e.g., error de localización 2D, intervalo de tiempo entre la aparición del objeto en el ground-truth y su detección en el sistema, ...). En este caso, se pueden obtener estadísticos de estos valores (media, desviación estándar, mínimo y máximo, ...) o ver su evolución en el tiempo.

- ▶ ...en general, se utilizan métricas que puedan mostrar:
 - **Un número de éxitos o fallas del algoritmo** (proviene de clasificación binaria). En este caso, se usan las siguientes definiciones:
 - **Verdadero Positivo (TP)**: El algoritmo detecta una situación real (existe en la ground-truth y en los resultados del algoritmo).
 - **Falso Negativo (FN)**: No se detectó una situación real (existe sólo en la ground-truth).
 - **Falso Positivo (FP)**: El algoritmo detecta una situación irreal (existe sólo en los resultados del algoritmo).
 - **Verdadero Negativo (TN)**: Elemento que no aparece ni en la groundtruth ni en los resultados del algoritmo.



- ▶ TP, FP, TN, FN también pueden dar más información para caracterizar a los algoritmos:

- **Precision** = $\frac{TP}{TP + FP}$, tasa de aciertos, contra aciertos y errores del algoritmo³.
- **Sensitivity** = $\frac{TP}{TP + FN}$, tasa de aciertos, contra todo lo que se debía detectar⁴.
- **Specificity** = $\frac{TN}{FP + TN}$, tasa de elementos correctamente no detectados, contra todo lo que no debía generar respuesta.
- **F-score** = $2 * \frac{\text{Precision} * \text{Sensitivity}}{\text{Precision} + \text{Sensitivity}}$, media armónica entre Precision y Sensitivity.
- **Acc:** = $\frac{TN + TP}{FP + FN + TN + TP}$


³El objetivo es medir la capacidad del modelo para no identificar erróneamente una señal negativa como positiva.

⁴Este criterio mide la capacidad del modelo para encontrar todas las señales positivas en el conjunto de datos.


Evaluación: Matriz de Confusión (Confusion Matrix)

- Es una herramienta de visualización típicamente usada en aprendizaje supervisado (muestras de entrenamiento etiquetadas).
- Cada columna de la matriz representa las instancias de clases predichas (e.g., la salida de un algoritmo).
- Cada fila representa las verdaderas instancias de la clase (e.g., etiquetas de las muestras, conocidas a priori).
- También, se encuentra la misma representación matricial transpuesta (en este caso, normalmente se aclara).

		prediction outcome		total
		p	n	
actual value	p'	True Positive	False Negative	P'
	n'	False Positive	True Negative	N'
total		P	N	



Ejemplo de Matriz de confusión



- ▶ Es fácil ver si el sistema se confunde entre dos o más clases.
 - ▶ Cuando un conjunto de datos es desbalanceado (número de muestras en diferentes clases varía mucho) la tasa de error del clasificador no es representativa del verdadero rendimiento del clasificador.
-

- ▶ e.g. clase A: 990 muestras - clase B: 10 muestras: **¿Qué pasa con la tasa de error si acierto en todas con A y en ninguna con B?.acierto**

- ▶ **Receiver Operating Characteristic (ROC)**, o curva ROC, es una gráfica que ilustra el rendimiento de un clasificador binario, ante la variación de su umbral.
- ▶ Se crea graficando la **TPR** (true positive rate) vs la **FPR** (false positive rate), en distintos umbrales.

Definiciones Clave

- ▶ **TPR (True Positive Rate):**

$$\text{TPR} = \frac{\text{TP}}{\text{TP} + \text{FN}} = \text{Sensibilidad}$$

- ▶ **FPR (False Positive Rate):**

$$\text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}} = 1 - \text{Especificidad}$$


Definiciones Clave

- TPR (True Positive Rate):

$$\text{TPR} = \frac{\text{TP}}{\text{TP} + \text{FN}} = \text{Sensibilidad}$$

- FPR (False Positive Rate):

$$\text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}} = 1 - \text{Especificidad}$$



Construcción de la Curva ROC


Paso 1: Definir los datos

Supongamos que tenemos un conjunto de etiquetas reales y predicciones probabilísticas del modelo.

Muestra	Etiqueta Real	Predicción (Probabilidad)
1	1	0.95
2	0	0.85
3	1	0.80
4	0	0.70
5	1	0.65
6	0	0.60
7	1	0.55
8	0	0.30
9	1	0.20
10	0	0.10

Tabla 1: Datos del modelo: Etiquetas reales y probabilidades predichas.

Ejemplo Curva ROC



Paso 2: Definir los umbrales

Los umbrales serán los valores únicos de las probabilidades predichas. Los umbrales son:

$$\text{Umbrales} = [0,95, 0,85, 0,80, 0,70, 0,65, 0,60, 0,55, 0,30, 0,20, 0,10]$$

Paso 3: Calcular TPR y FPR para cada umbral

Usamos las siguientes fórmulas:

$$\text{TPR} = \frac{\text{TP}}{\text{TP} + \text{FN}}, \quad \text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}}$$

La tabla siguiente resume los cálculos para cada umbral:

Umbral	TP	FP	FN	TN	TPR	FPR
0.95	1	0	4	5	0.20	0.00
0.85	1	1	4	4	0.20	0.20
0.80	2	1	3	4	0.40	0.20
0.70	2	2	3	3	0.40	0.40
0.65	3	2	2	3	0.60	0.40
0.60	3	3	2	2	0.60	0.60
0.55	4	3	1	2	0.80	0.60
0.30	4	4	1	1	0.80	0.80
0.20	5	4	0	1	1.00	0.80
0.10	5	5	0	0	1.00	1.00

Tabla 2: Cálculos de TPR y FPR para cada umbral.


Construcción de Curva ROC

Paso 4: Graficar la curva ROC


Con los valores de **TPR** y **FPR** calculados, podemos trazar la curva ROC. Los puntos clave para la curva son:

FPR = [0,00, 0,20, 0,20, 0,40, 0,40, 0,60, 0,60, 0,80, 0,80, 1,00]

TPR = [0,20, 0,20, 0,40, 0,40, 0,60, 0,60, 0,80, 0,80, 1,00, 1,00]



Ejemplo de Curva ROC



Búsqueda en Malla (Grid Search)

- ▶ **Grid Search** es una técnica de optimización utilizada para encontrar la combinación óptima de hiperparámetros en un modelo de ML.
- ▶ Se define una malla de posibles valores para cada hiperparámetro.
- ▶ El modelo se entrena y evalúa exhaustivamente con cada combinación posible de hiperparámetros en la malla.

Pasos del Grid Search

1. **Definir los hiperparámetros:** Seleccionar los hiperparámetros del modelo que se desean ajustar.
 2. **Establecer el rango de valores:** Especificar los valores posibles para cada hiperparámetro.
 3. Entrenar el modelo con cada combinación de hiperparámetros y evaluarlo utilizando un método como la validación cruzada.
 4. **Seleccionar la mejor combinación:** Escoger la combinación de hiperparámetros que proporcione el mejor rendimiento según la métrica de evaluación seleccionada.
- ▶ Puede ser computacionalmente costoso si hay muchos hiperparámetros o un gran número de valores posibles para cada uno.
 - ▶ *Random Search* o técnicas más avanzadas como *Bayesian Optimization*.

Ejemplo de GridSearch


- Parameters are found by training the model.
- Hyperparameters are set by the data scientist before training

```
Test_Hyperparameters = [a, b, c, d]
```

Hyperparameter used
to make the model

model

Accuracy on test set




⁵<https://medium.com/@jackstalfort/hyperparameter-tuning-using-grid-search-and-random-search-f8750a464b35>

Grid Search

Pseudocode

```
Hyperparameter_One = [a, b, c]
```

```
Hyperparameter_Two = [x, y, z]
```




Random Search

Pseudocode

```
Hyperparameter_One = random.num(range)
```


```
Hyperparameter_Two = random.num(range)
```



- ▶ Definir un modelo de machine learning. Este modelo será entrenado múltiples veces con diferentes combinaciones de hiperparámetros.
- ▶ GridSearchCV entrena el modelo en todas las combinaciones de los hiperparámetros que definiste, evaluando cada combinación en la validación cruzada y almacenando los resultados.
- ▶ Selección del mejor modelo: Después de probar todas las combinaciones, selecciona la que dio los mejores resultados según la métrica de evaluación definida (como accuracy, F-score, RMSE, entre otras).

Métricas de evaluación para problemas de segmentación

- Índice de Jaccard (IoU): $IoU = TP / (TP + FP + FN)$
 - Mide la superposición entre la segmentación predicha y la real⁶.




- Índice de Dice (similar al IoU, mide la superposición.):

$$Dice = 2TP / (2TP + FP + FN)$$

$$Dice = \frac{2 \times \text{Area of overlap}}{\text{Total area}} = \frac{2 \times \text{Prediction} \cap \text{Ground truth}}{\text{Prediction} \cup \text{Ground truth}}$$

⁶ Área de intersección / Área de unión (1 = superposición perfecta, 0 = ninguna superposición).

Métricas de evaluación para problemas de segmentación



► Distancia de Hausdorff:

- Máxima distancia entre puntos de dos segmentaciones.
- Evalúa la precisión de los contornos.

► Métricas basadas en volumen:

- Útiles en segmentación 3D (imágenes médicas). Miden la similitud entre volúmenes.



UNIVERSIDAD TÉCNICA
FEDERICO SANTA MARÍA

Métricas de Evaluación

EIN087B - Ciencia de Datos
Paralelo 701

Profesor: Jorge Portilla G.
`jorge.portilla@usm.cl`

Departamento de Electrónica e Informática
Universidad Técnica Federico Santa María
Concepción, Chile