



DOCTORADO EN
**INTELIGENCIA
ARTIFICIAL**



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA



UCSC



UNIVERSIDAD DEL BÍO-BÍO

Aprendizaje automático - Sesión 1

Introducción a Machine Learning

Doctorado en Inteligencia Artificial

Jorge Portilla

Departamento de Electrónica e Informática
Universidad Técnica Federico Santa María
Concepción, Chile

USM - Weekly Schedule



August 14	●	Introduction to Machine Learning
August 21	●	Linear and Logistic Regression
August 28	●	Dimensionality Reduction (PCA and LDA) and t-SNE
September 4	●	Principal Components Regression, K-Nearest Neighbors, and K-Means Algorithms
September 11	●	Support Vector Machine
September 25	●	Bagging & Boosting
October 2	●	Intro to ML implementation in Hardware, Hyperparameter tuning with RayTune, *Test
October 9	●	Homework presentation

UdeC - Weekly Schedule



October 16	●	Introduction to Artificial Neural Networks
October 23	●	Introduction to Deep Learning
October 30	●	Convolutional Neural Networks
November 6	●	Recurrent Neural Networks
November 13	●	Recurrent Neural Networks II
November 20	●	Generative Deep Learning
November 27	●	Transformer
December 4	●	Project presentation

The Curse of Dimensionality



1

- ▶ *Curse of dimensionality* surge cuando se analizan datos en espacios de alta dimensión.
- ▶ En la derecha, una variable con 10 regiones de interés. Con suficientes ejemplos los [algoritmos de aprendizaje](#) pueden generalizar correctamente.
- ▶ Se requieren exponencialmente más datos para cubrir todas las posibles configuraciones (datos dispersos dificulta la generalización).


¹Goodfellow, I., Bengio, Y., Courville, A. (2016). Deep Learning. MIT Press.

La ley de Moore

Establece que la cantidad de transistores en un microprocesador se duplicará aproximadamente cada dos años, y que el rendimiento del chip también lo hará.


- ▶ Con el aumento de la capacidad computacional, es posible procesar grandes volúmenes de datos de alta dimensión de manera más eficiente.
- ▶ Hoy en día se piensa que la ley de Moore ha alcanzado su punto más alto debido a que las limitaciones en cuanto a la fabricación de los chips dramáticamente podrían hacer retroceder dicha ley en unos cuantos años.


Ley de Moore



La masificación de las herramientas computacionales siempre ha estado limitada por la capacidad de cómputo y memoria. Sin embargo, ya en los años 70 se identificó que la capacidad de los sistemas computacionales crece también a un patrón exponencial.

- ▶ La duplicación que establece la ley de Moore comenzó a fallar, debido al calor que se genera con la miniaturización requerida para alcanzar cierto grado de integración de los componentes como los transistores.
- ▶ Al continuar esta tendencia de duplicación se llegará al punto en que el comportamiento de los electrones estará regido por incertidumbres cuánticas siendo los transistores poco confiables.
- ▶ Fabricantes trabajan en alternativas para obtener más potencia de cálculo, y en la fabricación de chips especializados para la aceleración de algoritmos.






- ³ Capacidad que exhiben las **herramientas** para realizar tareas que requieren **inteligencia**.
- ▶ Independiente de los componentes, aplicación, razonamiento, etc.

³<https://betterworld.mit.edu/computing-and-artificial-intelligence-humanistic-perspectives-from-mit/>

Historia de la Inteligencia Artificial




4

⁴<https://qbi.uq.edu.au/brain/intelligent-machines/history-artificial-intelligence>

Historia de la Inteligencia Artificial

- ▶ **1642:** Blaise Pascal construye la primera máquina de calcular mecánica.
- ▶ **1837:** Charles Babbage y Ada Lovelace diseñan la primera máquina programable.
- ▶ **1943:** Warren McCulloch y Walter Pitts establecen las bases de las redes neuronales.
- ▶ **1950:** Alan Turing introduce el test de Turing como una manera de probar la inteligencia de una máquina.
- ▶ **1955:** Durante una conferencia, se acuña el término "inteligencia artificial".
- ▶ **1965:** Se crea ELIZA, un programa de procesamiento de lenguaje natural.
- ▶ **1980s:** Edward Feigenbaum desarrolla sistemas expertos que emulan las decisiones de expertos humanos.
- ▶ **1997:** El programa Deep Blue de IBM vence al campeón mundial de ajedrez Garry Kasparov.
- ▶ **2002:** iRobot lanza Roomba, una aspiradora autónoma que evita obstáculos.
- ▶ **2009:** Google construye el primer coche autónomo capaz de manejar condiciones urbanas.
- ▶ **2011:** Watson de IBM vence a campeones del programa de concursos Jeopardy!.
- ▶ **2011-2014:** Se desarrollan asistentes personales como Siri, Google Now y Cortana.
- ▶ **2014:** Ian Goodfellow crea las Redes Generativas Antagónicas (GAN).
- ▶ **2016:** AlphaGo vence al jugador profesional de Go Lee Sedol 4-1.
- ▶ **2018:** La mayoría de las universidades tienen cursos en inteligencia artificial.



⁵<https://k21academy.com/datascience-blog/deep-learning/dl-vs-ml/>

¿Qué es aprendizaje automático?

"A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P , its performance at tasks in T , as measured by P , improves with experience E ."

— *Tom Mitchell*

Arthur Samuel

"Machine learning is the field of study that gives computers the ability to learn without being explicitly programmed"

Machine Learning (ML) es el campo científico que estudia los algoritmos que permiten a los ordenadores mejorar su rendimiento en una tarea específica mediante un proceso de aprendizaje iterativo en lugar de mediante reglas programadas explícitamente.

Algorithm 1 Identificar si es un perro o no

```
1: procedure IdentificarPerro(imagen)
2:   if imagen tiene características de perro then
3:     Return "Es un perro"
4:   else
5:     Return "No es un perro"
6:   end if
7: end procedure
```

Introducción al aprendizaje a partir de ejemplos

- Supongamos que tenemos un conjunto de datos que da el peso, el sexo y las calorías al día de 40 personas.

Peso (kg)	Sexo	Calorías al día
70	Masculino	2500
55	Femenino	2000
65	Masculino	2200
$\vdots$	$\vdots$	$\vdots$

- Nos gustaría predecir el consumo de calorías al día de otras personas.
- En este caso, el peso y el género se llaman **input features**. Cada **vector input** x_m tiene estas dos características.
- El consumo de calorías por día y_m se denomina **target**.
- Un par (x_m, y_m) es un ejemplo de entrenamiento. Un **train set** es un grupo de M ejemplos de entrenamiento $S_M = \{(x_m, y_m)\}, m = 1, \dots, M$.

- Features pueden ser **numerical** o **categorical**.
- Sea $\mathcal{X}$ el espacio de características (**feature space**), y $\mathcal{Y}$ el espacio de salida (**output space**).
- Nuestro objetivo es obtener un mapeo $f : \mathcal{X} \rightarrow \mathcal{Y}$, comúnmente llamado hipótesis o aprendiz, donde $\mathcal{X} \subseteq \mathbb{R}^n$ y $\mathcal{Y} \subseteq \mathbb{R}$.
- Sea S el espacio que abarca las muestras posibles, extraídas de una distribución desconocida $P(\mathbf{x}, y)$.
- Un algoritmo de aprendizaje es un mapa desde el espacio de conjuntos de entrenamiento al espacio de hipótesis $\mathcal{H}$ de posibles soluciones funcionales.

$$A : S \rightarrow \mathcal{H}$$

Para un conjunto de entrenamiento específico S_M , el algoritmo produce una hipótesis f tal que:

$$A(S_M) = f.$$

Podemos proporcionar una descripción genérica de un algoritmo ML de la siguiente manera:


- ▶ Dado un espacio de hipótesis $\mathcal{H}$ definido por el modelo ML y sus parámetros, un conjunto de ejemplos $\mathbf{x}^{(i)} \in T$ para $i = 1, \dots, S$ que alimentar al modelo para su entrenamiento.
- ▶ Donde $T = \{(\mathbf{x}^{(1)}, \mathbf{y}^{(1)}), \dots, (\mathbf{x}^{(S)}, \mathbf{y}^{(S)})\}$ of S es un set de entrenamiento.
- ▶ Función de coste $\mathcal{J}(\mathbf{h}(\mathbf{x}^{(i)}))$ que cuantifica la calidad de la elección de una hipótesis $\mathbf{h} \in \mathcal{H}$ para un ejemplo $\mathbf{x}^{(i)}$.

- ▶ El objetivo general de un algoritmo ML es encontrar una hipótesis óptima $\mathbf{h}^*$ tal que

$$\mathbf{h}^* = \arg \min_{\mathbf{h} \in \mathcal{H}} \frac{1}{S} \sum_{i=1}^S \mathcal{J}(\mathbf{h}(\mathbf{x}^{(i)})). \quad (1)$$



- ▶ Si el **target** es continuo, tenemos un problema de regresión.
- ▶ Si el **target** puede tomar un número finito k de valores discretos, entonces se tiene un problema de clasificación. Si $k = 2$ el problema es llamada como clasificación binaria.



- ▶ Si el **target** es continuo, tenemos un problema de regresión.
- ▶ Si el **target** puede tomar un número finito k de valores discretos, entonces se tiene un problema de clasificación. Si $k = 2$ el problema es llamada como clasificación binaria.

- ▶ Uno de los principales retos es construir un método o algoritmo automático capaz de estimar ejemplos futuros basándose en el fenómeno observado observado en el conjunto de entrenamiento.
- ▶ Esta propiedad clave de un algoritmo se conoce como **capacidad de generalización**.
- ▶ Los algoritmos que memorizan las muestras del train set pero tienen un pobre desempeño con ejemplos desconocidos, presentan un problema que se conoce como **overfitting**.

Essentially, all models are wrong, but some are useful."George Box, 1987

► Predicción de Y :

- Cuando los valores de X están disponibles pero no los de Y , se puede predecir Y utilizando $\hat{f}(X)$.
- $\hat{f}$ es tratado como una **caja negra** en muchos casos, siempre que proporcione predicciones precisas.

Porque estimar f ?

► Predicción de Y :

- Cuando los valores de X están disponibles pero no los de Y , se puede predecir Y utilizando $\hat{f}(X)$.
- $\hat{f}$ es tratado como una **caja negra** en muchos casos, siempre que proporcione predicciones precisas.

Ejemplo

Predicción del riesgo de una reacción adversa a un medicamento basado en características de una muestra de sangre del paciente.

► Exactitud de $\hat{Y}$:

- Depende de dos tipos de error: **error reducible** y **error irreducible**.

Porque estimar f ?

► Predicción de Y :

- Cuando los valores de X están disponibles pero no los de Y , se puede predecir Y utilizando $\hat{f}(X)$.
- $\hat{f}$ es tratado como una **caja negra** en muchos casos, siempre que proporcione predicciones precisas.

Ejemplo

Predicción del riesgo de una reacción adversa a un medicamento basado en características de una muestra de sangre del paciente.

► Exactitud de $\hat{Y}$:

- Depende de dos tipos de error: **error reducible** y **error irreducible**.
- El error reducible puede disminuirse mejorando $\hat{f}$.
- El error irreducible no puede eliminarse porque incluye la variabilidad inherente de ϵ .

► Ecuación del Error:

$$E(Y - \hat{Y})^2 = [f(X) - \hat{f}(X)]^2 + \text{Var}(\epsilon) \quad (2)$$

- El primer término es el error reducible.
- El segundo término es el error irreducible.

- El objetivo es encontrar una función $\hat{f}$ tal que $Y \approx \hat{f}(X)$ para cualquier observación (X, Y) .
- En términos generales, la mayoría de los métodos de aprendizaje estadístico se pueden caracterizar como *paramétricos o no paramétricos*.

- ▶ Un modelo paramétrico implica asumir una forma funcional específica para la relación entre las variables predictoras y la respuesta.

- ▶ **Asunción de la Forma Funcional:**

- Por ejemplo, una suposición simple es que f es lineal en X :

$$f(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p.$$

- ▶ **Ajuste del Modelo:**

- Después de seleccionar un modelo, se ajusta utilizando los datos de entrenamiento para estimar los parámetros $\beta_0, \beta_1, \dots, \beta_p$.
 - El método más común para ajustar el modelo lineal es los mínimos cuadrados ordinarios.

- ▶ **Ventajas:**

- Simplificación del problema de estimación - Eficiencia computacional.

- ▶ **Desventajas:**

- Riesgo de mala especificación del modelo.

- ▶ Los métodos no paramétricos no hacen suposiciones explícitas sobre la forma funcional de f .
- ▶ Buscan una estimación de f que se acerque lo más posible a los puntos de datos.
- ▶ **Ventajas:**
 - Flexibilidad para ajustarse a una amplia variedad de formas de f .
- ▶ **Desventajas:**
 - Pueden capturar patrones complejos y no lineales en los datos.
- ▶ **Ejemplo:**
 - K-Nearest Neighbors (K-NN), SVM con kernels no lineales, Árboles de decisión, etc.

El equilibrio entre la precisión de la predicción y la interpretabilidad del modelo



En general, a medida que aumenta la flexibilidad de un método, su interpretabilidad disminuye.

- ▶ Los métodos menos flexibles sólo pueden producir una gama pequeña de formas para estimar f .
 - Ejemplo: La regresión lineal es inflexible porque sólo puede generar funciones lineales.
- ▶ Los métodos más flexibles pueden generar una gama más amplia de formas para estimar f .
 - Los métodos no lineales, como bagging, boosting, support vector machines (SVM) con kernels no lineales y las redes neuronales (*deep learning*) son enfoques muy flexibles que resultan más **difíciles de interpretar**.

¿Por qué Utilizar Métodos Más Restrictivos?

- ▶ Los métodos restrictivos son más interpretables.
- ▶ Si el objetivo es la **inferencia**, los modelos restrictivos son preferibles.
 - Ejemplo: Un modelo lineal es fácil de entender en términos de la relación entre Y y los predictores $X_1, X_2, \dots, X_p$.
- ▶ Los métodos flexibles pueden hacer difícil comprender la asociación de cada predictor individual con la respuesta.

Entender la relación entre las variables independientes (predictoras) y la variable dependiente (respuesta).

- Enfoque en la interpretación de los coeficientes y la significancia estadística.

Ejemplo

En un estudio médico, entender cómo factores como la dieta, el ejercicio y la edad influyen en la presión arterial.

- Modelos Preferidos: Modelos lineales (e.g., regresión lineal).

Ventaja: Alta interpretabilidad. Desventaja: Baja flexibilidad.

Predecir los valores futuros o desconocidos de la variable dependiente utilizando las variables independientes.

- Enfoque en la precisión de las predicciones.

Ejemplo

En un sistema de recomendación de productos, predecir qué productos comprará un cliente basado en su historial de compras.

- Modelos Preferidos: Modelos flexibles (e.g., árboles de decisión, bosques aleatorios, redes neuronales).

Alta flexibilidad y precisión. Baja interpretabilidad.

► Aprendizaje Supervisado

- Objetivo: Predecir una respuesta específica (etiquetada) basada en datos de entrada.
- Requiere un conjunto de datos de entrenamiento con respuestas conocidas.
- Ejemplos de problemas: Clasificación y regresión.
- Ejemplos de algoritmos: Regresión lineal, regresión logística, árboles de decisión, redes neuronales.

► Aprendizaje Supervisado

- Objetivo: Predecir una respuesta específica (etiquetada) basada en datos de entrada.
- Requiere un conjunto de datos de entrenamiento con respuestas conocidas.
- Ejemplos de problemas: Clasificación y regresión.
- Ejemplos de algoritmos: Regresión lineal, regresión logística, árboles de decisión, redes neuronales.

► Aprendizaje No Supervisado

- Objetivo: Encontrar patrones o estructuras ocultas en datos no etiquetados.
- No requiere respuestas conocidas en el conjunto de datos.
- Ejemplos de problemas: Agrupamiento (clustering) y reducción de dimensionalidad.
- Ejemplos de algoritmos: K-means, análisis de componentes principales (PCA), entre otros.

► Variables Cuantitativas (Regresión)

- Toman valores numéricos.
- Ejemplos: edad, altura, ingreso, valor de una casa, precio de una acción.
- Problemas de regresión: El objetivo es predecir un valor numérico.
 - Ejemplo: Regresión lineal.

► Variables Cualitativas (Clasificación)

- Toman valores en una de K diferentes clases o categorías.
- Ejemplos: estado civil (casado o no), marca de producto (A, B, o C), diagnóstico de cáncer, entre otros.
- Problemas de clasificación: El objetivo es predecir una categoría.
 - Ejemplo: Regresión logística.

En un marco de aprendizaje supervisado, el modelo de ML adapta un conjunto de parámetros internos utilizando **pares de entrada-salida etiquetados** para obtener una función de mapeo o hipótesis $\mathbf{h}$.

- ▶ Dado un conjunto de entrenamiento $T = (\mathbf{x}^{(1)}, \mathbf{y}^{(1)}), \dots, (\mathbf{x}^{(S)}, \mathbf{y}^{(S)})$ de S vectores de entrada $\mathbf{x}^{(i)}$ y sus correspondientes salidas $\mathbf{y}^{(i)}$.
- ▶ Considerando un conjunto de parámetros $\boldsymbol{\theta}$ derivado de la arquitectura del modelo para caracterizar el espacio de funciones de mapeo $\mathbf{h}(\mathbf{x}; \boldsymbol{\theta}) \in \mathcal{H}$
- ▶ El objetivo general de un algoritmo de aprendizaje supervisado es encontrar un conjunto de parámetros $\boldsymbol{\theta}^*$ que generen un buen predictor de manera que

$$\boldsymbol{\theta}^* \approx \arg \min_{\mathbf{h}(\mathbf{x}; \boldsymbol{\theta}) \in \mathcal{H}} \frac{1}{S} \sum_{i=1}^S \mathcal{J}(\mathbf{h}(\mathbf{x}^{(i)}; \boldsymbol{\theta}), \mathbf{y}^{(i)}), \quad (3)$$

► Selección de Métodos

- Para respuesta cuantitativa, se utilizan métodos de regresión.
- Para respuesta cualitativa, se utilizan métodos de clasificación.
- Algunos métodos pueden aplicarse a ambos tipos de respuestas (e.g., K-nearest neighbors, boosting).

► Tipo de Predictores

- Generalmente, el tipo de predictores (cuantitativos o cualitativos) es menos importante.
- La mayoría de los métodos de aprendizaje estadístico pueden aplicarse independientemente del tipo de predictores, siempre que los predictores cualitativos se codifiquen adecuadamente⁶.

⁶one-hot encoding

- ▶ Para evaluar el rendimiento de un método de aprendizaje estadístico, es necesario medir qué tan bien sus predicciones coinciden con los datos observados.
- ▶ En el contexto de la **regresión**, la medida más comúnmente utilizada es el **error cuadrático medio (MSE)**.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{f}(x_i))^2 \quad (4)$$

- ▶ Donde $\hat{f}(x_i)$ es la predicción para la i -ésima observación.
- ▶ El MSE será pequeño si las predicciones están muy cerca de las respuestas verdaderas y será grande si para algunas observaciones las predicciones y las respuestas verdaderas difieren sustancialmente.
- ▶ Precisión de las predicciones en datos no vistos previamente (datos de prueba).

Medir la calidad del ajuste (2)

En un entorno de clasificación, evaluamos la calidad del ajuste utilizando diferentes métricas que comparan las predicciones del modelo con las etiquetas verdaderas.

- **Accuracy:** La proporción de predicciones correctas sobre el total de predicciones.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Precisión:** La proporción de verdaderos positivos sobre el total de predicciones positivas.

$$\text{Precisión} = \frac{TP}{TP + FP}$$

- **Recall (Sensibilidad):** La proporción de verdaderos positivos sobre el total de positivos reales.


$$\text{Recall} = \frac{TP}{TP + FN}$$

En las próximas sesiones se profundizará en las métricas de evaluación (Curva ROC, F1-score, entre otros.)

- ▶ El desafío principal es construir un algoritmo de aprendizaje capaz de **extrapolar**.
- ▶ Es decir, estimar ejemplos futuros basados en el fenómeno observado en el conjunto de entrenamiento (**error de generalización**).
- ▶ Esta propiedad clave de un algoritmo se conoce como **capacidad de generalización**.
- ▶ Por otro lado, encontramos algoritmos que memorizan las muestras de entrenamiento pero tienen un rendimiento predictivo pobre con ejemplos desconocidos; este problema es conocido como **sobreajuste** (overfitting).


La relación entre sesgo y varianza

- ▶ El desafío principal es construir un algoritmo de aprendizaje capaz de **extrapolar**.
- ▶ Es decir, estimar ejemplos futuros basados en el fenómeno observado en el conjunto de entrenamiento (**error de generalización**).
- ▶ Esta propiedad clave de un algoritmo se conoce como **capacidad de generalización**.
- ▶ Por otro lado, encontramos algoritmos que memorizan las muestras de entrenamiento pero tienen un rendimiento predictivo pobre con ejemplos desconocidos; este problema es conocido como **sobreajuste** (overfitting).
- ▶ Si calculamos un modelo diferente para cada muestra de entrenamiento que hemos recolectado;
 - El **sesgo** es el conjunto de puntos que no pueden ser bien predichos por el modelo.
 - La **varianza** mide cuán diferentes son las predicciones a lo largo de las muestras de entrenamiento.



- ▶ Desde el punto de vista del aprendizaje automático, este compromiso está fuertemente relacionado con la complejidad del modelo f .
- ▶ Un modelo con baja complejidad tiene un alto sesgo al cubrir los puntos de entrenamiento, lo que puede llevar a un **subajuste (underfitting)**.
- ▶ Sin embargo, si la complejidad del modelo es demasiado alta, la predicción tiende a ser más cercana (menor sesgo) a los datos de entrenamiento y, en consecuencia, genera **sobreajuste**.

Sesgo y varianza trade-off



7

- ▶ En la izquierda de la gráfica, tanto el error de entrenamiento como el error de generalización son altos, lo que indica un régimen de **subajuste**.
- ▶ A medida que aumentamos la capacidad, el error de entrenamiento disminuye, pero la brecha entre el error de entrenamiento y el error de generalización (la brecha de generalización) aumenta.
- ▶ Eventualmente, el tamaño de esta brecha supera la disminución del error de entrenamiento, llevando al régimen de **sobreajuste**.
- ▶ La **capacidad óptima** es el punto donde se minimiza el error de generalización.
- ▶ Alta varianza, ante pequeñas variaciones en los datos de entrenamiento conduce a un modelo completamente diferente.

⁷Goodfellow, I., Bengio, Y., Courville, A. (2016). Deep Learning. MIT Press.

Regresión Lineal

- ▶ Es uno de los métodos que aplican estadística más utilizados.
- ▶ Se usa para describir la relación entre el **promedio (tendencia)** de una variable y los valores tomados por otras variables $\Rightarrow$ **regresión**.
- ▶ A veces tenemos varios modelos plausibles, y queremos seleccionar cuál es el más apropiado $\Rightarrow$ **Análisis de varianza**.

Podríamos aproximar el tiempo total de viaje diario y como una función lineal de la distancia recorrida y el número de entregas realizadas:

$$f(x) = \beta_0 + \beta_1 x^{(1)} + \beta_2 x^{(2)},$$


donde β_i , $i = 0, 1, 2$ son los parámetros del modelo lineal.

- ▶ Así, el espacio de funciones lineales que mapean de $\mathcal{X}$ a $\mathcal{Y}$ es **paramétrico**.
- ▶ Definimos $x^{(0)} = 1$ para definir el modelo lineal en forma matricial:

$$f(x) = \sum_{i=0}^I \beta_i x^{(i)} = \beta^T x,$$


donde I es el número de características.

Ejemplo gráfico de regresión lineal



- ▶ Encontrar un hiperplano.
- ▶ Criterio mínimos cuadrados o *least square*.

Ejemplo gráfico de regresión lineal



En un entorno tridimensional, con dos predictores y una respuesta, la línea de regresión por mínimos cuadrados se convierte en un plano. El plano se elige para minimizar la suma de las distancias verticales al cuadrado entre cada observación.

¿Cómo seleccionamos los β 's?

- Podemos obtener los parámetros del modelo minimizando la función de pérdida cuadrática sobre el conjunto de entrenamiento:

$$J(\beta) = \frac{1}{2} \sum_{m=1}^M (f(x_m) - y_m)^2$$

donde $\beta = (\beta_0, \beta_1, \dots, \beta_I)^T$.

- Necesitamos elegir β que minimice $J(\beta)$.

Algoritmo Least Mean Squares (LMS)

- Este problema puede expresarse en forma matricial:

$$J(\beta) = \frac{1}{2}(Y - X\beta)^T(Y - X\beta),$$

donde X es una matriz de $N \times (I + 1)$.

Desde cálculo matricial

- Si x es un vector columna:

$$\frac{\partial u^T v}{\partial x} = \frac{\partial u}{\partial x} \cdot v + \frac{\partial v}{\partial x} \cdot u$$

- $\frac{\partial Ax}{\partial x} = A^T$

- Entonces,

$$\frac{\partial J(\beta)}{\partial \beta} = -X^T(Y - X\beta)$$

$$\frac{\partial^2 J(\beta)}{\partial \beta \partial \beta^T} = X^T X$$

- Igualando la primera derivada a cero obtenemos las ecuaciones normales:

$$X^T(Y - X\beta) = 0 \implies \hat{\beta} = (X^T X)^{-1} X^T Y$$

Esta es la solución analítica.

- Entonces,

$$\frac{\partial J(\beta)}{\partial \beta} = -X^T(Y - X\beta)$$
$$\frac{\partial^2 J(\beta)}{\partial \beta \partial \beta^T} = X^T X$$

- Igualando la primera derivada a cero obtenemos las ecuaciones normales:

$$X^T(Y - X\beta) = 0 \implies \hat{\beta} = (X^T X)^{-1} X^T Y$$

Esta es la solución analítica.

- ¿Qué sucedería si la solución analítica es costosa de calcular debido a los grandes volúmenes de datos?

- Entonces,

$$\frac{\partial J(\beta)}{\partial \beta} = -X^T(Y - X\beta)$$
$$\frac{\partial^2 J(\beta)}{\partial \beta \partial \beta^T} = X^T X$$

- Igualando la primera derivada a cero obtenemos las ecuaciones normales:

$$X^T(Y - X\beta) = 0 \implies \hat{\beta} = (X^T X)^{-1} X^T Y$$

Esta es la solución analítica.

- ¿Qué sucedería si la solución analítica es costosa de calcular debido a los grandes volúmenes de datos?
- Métodos iterativos como el descenso del gradiente se convierten en una opción más viable y eficiente.

- Asumiendo que el modelo lineal es correcto, es decir, $Y = X\beta + \epsilon$ para algún β desconocido.
- Además, asumimos que $E[\epsilon] = 0$ y $\text{Cov}(\epsilon) = E[\epsilon\epsilon^T] = \sigma^2 I$ (ruido no correlacionado). De la solución de mínimos cuadrados $\beta_{ls} = (X^T X)^{-1} X^T Y$. Así,

$$\begin{aligned} E[\beta_{ls}] &= E \left[(X^T X)^{-1} X^T Y \right] \\ &= (X^T X)^{-1} X^T E[Y] = (X^T X)^{-1} X^T X \beta = \beta, \end{aligned} \tag{5}$$

$$\begin{aligned} E[\beta_{ls}] &= E \left[(X^T X)^{-1} X^T Y \right] \\ &= (X^T X)^{-1} X^T E[Y] = (X^T X)^{-1} X^T X \beta = \beta, \end{aligned} \quad (5)$$

- ▶ Es decir, β_{ls} es un estimador insesgado de β .
- ▶ Además, el error

$$\begin{aligned} \beta_{ls} - E[\beta_{ls}] &= \beta_{ls} - \beta \\ &= (X^T X)^{-1} X^T Y - \beta \\ &= (X^T X)^{-1} X^T Y - (X^T X)^{-1} X^T X \beta \\ &= (X^T X)^{-1} X^T (Y - X \beta) \\ &= (X^T X)^{-1} X^T \epsilon \end{aligned} \quad (6)$$

⁸Si se repite el experimento muchas veces, con diferentes muestras de datos pero bajo el mismo modelo verdadero, el valor promedio de los estimadores β_{ls} que obtengas sería exactamente igual al verdadero valor β .

⁹El error en los coeficientes estimados (desviación respecto al valor verdadero) depende únicamente de los errores de medición ϵ y de la estructura de X .

- ▶ Así, a partir de la suposición $E[\epsilon\epsilon^T] = \sigma^2 I$ obtenemos

$$\begin{aligned}\text{Cov}(\beta_{ls}) &= E \left[(\beta_{ls} - E[\beta_{ls}]) (\hat{\beta}^{ls} - E[\beta_{ls}])^T \right] \\ &= E \left[(X^T X)^{-1} X^T \epsilon \epsilon^T X (X^T X)^{-1} \right] \\ &= (X^T X)^{-1} X^T E \left[\epsilon \epsilon^T \right] X (X^T X)^{-1} \\ &= \sigma^2 (X^T X)^{-1} X^T X (X^T X)^{-1} \\ &= \sigma^2 (X^T X)^{-1}\end{aligned}$$

- ▶ Típicamente, la varianza σ^2 se estima como

$$\hat{\sigma}^2 = \frac{1}{N - I - 1} \sum_{m=1}^M (y_m - \hat{y}_m)^2$$

¹⁹La variabilidad de los coeficientes β_{ls} viene directamente del ruido, y que bajo el supuesto de ruido gaussiano e independiente la matriz $\text{Cov}(\beta_{ls}) = \sigma^2 (X^T X)^{-1}$



UNIVERSIDAD TÉCNICA
FEDERICO SANTA MARÍA

Aprendizaje automático - Sesión 1

Introducción a Machine Learning

Doctorado en Inteligencia Artificial

Jorge Portilla

Departamento de Electrónica e Informática
Universidad Técnica Federico Santa María
Concepción, Chile