



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA



Procesamiento y Visualización de Datos

EIN087B - Ciencia de Datos

Profesor: Jorge Portilla G.
`jorge.portilla@usm.cl`



Departamento de Electrónica e Informática
Universidad Técnica Federico Santa María
Concepción, Chile

Libro de referencia



Libro disponible gratuitamente en: <https://www.statlearning.com/>

Data Science Books



► Machine Learning

- The Elements of Statistical Learning, Hastie et al., 2017. [Link](#)
- Hands On Machine Learning with Scikit Learn, Keras, and TensorFlow, Geron, 2019. [Link](#)

► Math and others

- Mathematics for Machine Learning, Deisenroth et al., 2020. [Link](#)
- The Linux Command Line, Shotts, 2019. [Link](#)

Fuente datos



- ▶ **Registros y bases de datos:** Información almacenada en sistemas digitales o físicos.
- ▶ **Sensores y dispositivos:** Datos obtenidos de herramientas de medición y monitoreo.
- ▶ **Investigaciones y publicaciones:** Estudios científicos, artículos y reportes técnicos.
- ▶ Información recolectada a través de métodos de consulta.

Para analizar datos en cualquier estructura de manera efectiva es importante entender algunos conceptos clave:

VARIABLE

Es una característica o atributo que se mide u observa en un conjunto de datos.

OBSERVACIÓN

Es un conjunto de valores que se registran para una variable en particular.



DISTRIBUCIÓN

Es una característica o atributo que se mide u observa en un conjunto de datos.

CORRELACIÓN

Es la relación entre dos variables en un conjunto de datos.



EJEMPLOS:

VARIABLE

Edad, género, diagnóstico.

OBSERVACIÓN

Registro de un paciente, un dato de un sensor de salud.

DISTRIBUCIÓN

Distribución de edades en una población, distribución de diagnósticos en un hospital.

CORRELACIÓN

Correlación entre la edad y la presión arterial.
Correlación entre el género y la incidencia de una enfermedad.



EJEMPLOS:

VARIABLE

Edad, género, diagnóstico.

OBSERVACIÓN

Registro de un paciente, un dato de un sensor de salud.

DISTRIBUCIÓN

Distribución de edades en una población, distribución de diagnósticos en un hospital.

CORRELACIÓN

Correlación entre la edad y la presión arterial.
Correlación entre el género y la incidencia de una enfermedad.

Tipos de datos

- ▶ Datos estructurados
- ▶ Datos no estructurados
- ▶ Datos semi-estructurados

Datos estructurados


ID Paciente	Nombre	Apellido	Fecha de Nacimiento	Sexo	Dirección	Teléfono
1	Juan	Pérez	01/01/1990	H	Av. Libertad 123	555-1234
2	María	García	02/02/1992	M	Calle 45 #23	555-5678
3	Pedro	Rodríguez	03/03/1995	H	Av. Independencia 456	555-9012
4	Ana	Sánchez	04/04/1991	M	Calle 12 #56	555-1111

Datos NO estructurados

Nombre: Juan Pérez
Edad: 35
Sexo: Masculino
Diagnóstico: Diabetes tipo 2
Medicamentos: - Metformina - Insulina
Alergias: - Penicilina

Archivos JSON y XML.

Fuente de datos



- ▶ **Registros y bases de datos:** Información almacenada en sistemas digitales o físicos.
- ▶ **Sensores y dispositivos:** Datos obtenidos de herramientas de medición y monitoreo.
- ▶ **Investigaciones y publicaciones:** Estudios científicos, artículos y reportes técnicos.
- ▶ Información recolectada a través de métodos de consulta.

Fuente de datos



- ▶ **Registros y bases de datos:** Información almacenada en sistemas digitales o físicos.
- ▶ **Sensores y dispositivos:** Datos obtenidos de herramientas de medición y monitoreo.
- ▶ **Investigaciones y publicaciones:** Estudios científicos, artículos y reportes técnicos.
- ▶ Información recolectada a través de métodos de consulta.



Label-studio <https://labelstud.io/templates/>

Problemas en los datos

Valores faltantes o duplicados

Valores inconsistentes

Ruido

Errores de formato

Problemas en los datos

Valores faltantes o duplicados

Valores inconsistentes

Ruido

Errores de formato

Técnicas y herramientas

Eliminación/Reemplazo de valores restantes

Corrección de formato

Eliminación de duplicados

Normalización

Escalado máximo-mínimo (Min-Max)

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Z-score (Estandarización)

$$x' = \frac{x - \mu}{\sigma}$$

Normalización máxima (Max Norm)

$$x' = \frac{x}{x_{\max}}$$

Normalización

Escalado máximo-mínimo (Min-Max)

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Z-score (Estandarización)

$$x' = \frac{x - \mu}{\sigma}$$

Normalización máxima (Max Norm)

$$x' = \frac{x}{x_{\max}}$$

Transformación de variables

Codificación One-Hot

Ejemplo: Rojo $\rightarrow (1, 0, 0)$, Azul $\rightarrow (0, 1, 0)$

Codificación ordinal

Ejemplo: Bajo (1), Medio (2), Alto (3)

Discretización de variables numéricas

Ejemplo: $[0, 10] \rightarrow$ "bajo", $[11, 20] \rightarrow$ "medio"

Medidas de tendencia central y dispersión

Media
(*promedio*)

Media aritmética:

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

Promedio de los valores de un conjunto de datos.

Medidas de tendencia central y dispersión

Media
(promedio)

Media aritmética:

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

Promedio de los valores de un conjunto de datos.



Desviación
estándar

Fórmula:

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2}$$

Mide la dispersión de los datos respecto a la media.

Restar la media o estandarizar: Al restar μ_x a los datos se centra el espacio en las medias, por lo que la media de los datos estandarizados es cero ($\mu_x = E[x] = 0$)



Varianza y covarianza

- **Varianza:** medida que indica qué tan dispersos están los valores con respecto a la media.


$$\text{var}(x) = \sigma_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_x)^2$$

- **Covarianza:** representa la tasa de cambio entre dos variables aleatorias.

$$\text{Cov}(x, y) = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_x)(y_i - \mu_y)$$

- **Correlación:** mide la relación lineal entre dos variables, estandarizando la covarianza.

$$\text{Corr}(x, y) = \frac{\text{Cov}(x, y)}{\sigma_x \sigma_y}$$



Matriz de covarianza

Sea el vector $\mathbf{x} = \{x_1, \dots, x_N\}$, un vector de variables aleatorias.

$$\mathbf{C}_x = \mathbf{C}_x^{N \times N} = (c_{ij} | c_{ij} = \text{Cov}(x_i, x_j))$$

Teniendo en cuenta que $\text{Cov}(x, x) = \sigma_x^2$ y sea $\mathbf{x} = \{x, y, z\}$:

$$\mathbf{C}_x = \begin{pmatrix} \sigma_x^2 & \text{Cov}(x, y) & \text{Cov}(x, z) \\ \text{Cov}(x, y) & \sigma_y^2 & \text{Cov}(y, z) \\ \text{Cov}(x, z) & \text{Cov}(y, z) & \sigma_z^2 \end{pmatrix}$$

- $\mathbf{C}_x$ es una matriz simétrica.
- La matriz de covarianza también se puede definir como:

$$\mathbf{C}_x = E[(\mathbf{x} - \mu_x)(\mathbf{x} - \mu_x)^T] = \frac{1}{n} \sum_{k=1}^n (\mathbf{x}_k \mathbf{x}_k^T - \mu_x \mu_x^T)$$

Datos tabulares

```
import pandas as pd
import numpy as np
import random
import matplotlib.pyplot as plt
import seaborn as sns

df = pd.read_csv('Salary Data.csv')
print(df.shape)
df.head()
```

✓ 28.1s



(375, 6)

	Age	Gender	Education Level	Job Title	Years of Experience	Salary
0	32.0	Male	Bachelor's	Software Engineer	5.0	90000.0
1	28.0	Female	Master's	Data Analyst	3.0	65000.0
2	45.0	Male	PhD	Senior Manager	15.0	150000.0
3	36.0	Female	Bachelor's	Sales Associate	7.0	60000.0
4	52.0	Male	Master's	Director	20.0	200000.0

Diferencias Clave entre Correlación y Covarianza

► Escala:



- La covarianza depende de las unidades de las variables.
- La correlación es adimensional, normalizada entre -1 y 1.



Diferencias Clave entre Correlación y Covarianza

► Escala:

- La covarianza depende de las unidades de las variables.
- La correlación es adimensional, normalizada entre -1 y 1.



► Comparabilidad:


- La covarianza no es directamente comparable entre distintos pares de variables.
- La correlación permite comparaciones directas entre diferentes pares de variables.

Correlación vs. Covarianza

- ▶ **Valores altos de correlación:** Los valores cercanos a 1 indican una fuerte correlación positiva entre las variables.
 - Experiencia y Edad (0.98): Existe una correlación muy alta entre los años de experiencia y la edad, lo cual es lógico, ya que generalmente a más edad se acumula más experiencia.
 - Experiencia y Salario (0.93): También hay una fuerte correlación positiva entre los años de experiencia y el salario, lo que sugiere que a mayor experiencia, mayor salario.
 - Edad y Salario (0.92): Hay una alta correlación entre la edad y el salario, lo cual indica que las personas mayores tienden a tener salarios más altos.
- ▶ **La matriz de covarianza** refleja que los cambios absolutos en experiencia y edad tienen una menor magnitud comparada con los cambios en el salario, lo que podría indicar que el salario tiene una mayor varianza o dispersión en los datos.
- ▶ Estas matrices son útiles para identificar relaciones lineales entre las variables y para entender la magnitud de sus variaciones conjuntas.


Detección de Outliers (Valores Atípicos)

Son datos que se desvían significativamente del patrón general de un conjunto de datos. Pueden ser causados por errores de medición, variabilidad natural o eventos excepcionales.



- **Método de la Distancia:** Identifica outliers basados en la distancia a la media o a otros puntos de datos (e.g., Z-score).
- **Método de la Densidad:** Detecta outliers como puntos con baja densidad de vecinos (e.g., DBSCAN).
- **Otros Métodos:** Incluyen métodos basados en modelos estadísticos, métodos de aprendizaje automático (e.g., Isolation Forest), etc.

Outliers




Boxplot: Resumen Visual de Datos

- ▶ **Mediana (Línea Amarilla):** Valor central, divide los datos en 50/50.
- ▶ **Caja (IQR):** Rango intercuartílico (Q1 a Q3), 50 % central de los datos.
 - Q1: 25 % de los datos por debajo.
 - Q3: 75 % de los datos por debajo.
- ▶ **Líneas "Mínimo" "Máximo":** Límites de datos no atípicos ($Q1 - 1.5 * IQR$, $Q3 + 1.5 * IQR$).
- ▶ **Outliers (Puntos Fuera de los Bigotes):** Valores atípicos, significativamente diferentes del resto.



Seaborn - sns.pairplot




Distribución Gaussiana (Normal)

Definición: Una variable aleatoria X sigue una distribución normal si su función de densidad de probabilidad es:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

- ▶ μ : media
- ▶ σ^2 : varianza
- ▶ Forma de campana, simétrica¹².



¹Algunos fenómenos naturales siguen esta distribución. Se utiliza para modelar variables continuas como la altura, el peso, la inteligencia, entre otras.


²La distribución normal es simétrica y tiene una curva en forma de campana, con la mayoría de los datos agrupados cerca de la media.

Distribución Uniforme

Definición: Una variable aleatoria X sigue una distribución uniforme en el intervalo $[a, b]$ si su función de densidad de probabilidad es:

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{en otro caso} \end{cases}$$

- ▶ Todos los valores tienen la misma probabilidad.
- ▶ Distribución rectangular.




Distribución Binomial

Definición: Una variable aleatoria X sigue una distribución binomial si cuenta el número de éxitos en n ensayos de Bernoulli³, con probabilidad de éxito p :

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k},$$

- ▶ Modela procesos de éxito/fracaso.
- ▶ Se aproxima a la normal para n grande.



³Experimentos aleatorios que tienen solo dos posibles resultados: éxito o fracaso. Ejemplo: lanzar una moneda.

- ▶ La distribución de Bernoulli, que describe la probabilidad de obtener éxito o fracaso en un solo ensayo.
- ▶ La distribución binomial, que modela el número de éxitos en una serie de n ensayos de Bernoulli.

Ejemplo: Probabilidad de obtener 3 caras en 5 lanzamientos

Supongamos que lanzamos una moneda justa $n = 5$ veces y queremos calcular la probabilidad de obtener exactamente $k = 3$ caras.

Paso 1: Usamos la fórmula de la distribución binomial

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k} \quad (1)$$

Sustituyendo los valores $n = 5$, $k = 3$, y $p = 0,5$:

$$P(X = 3) = \binom{5}{3} (0,5)^3 (1 - 0,5)^{5-3} \quad (2)$$

Paso 2: Calcular el coeficiente binomial

$$\binom{5}{3} = \frac{5!}{3!(5-3)!} = \frac{5!}{3!2!} \quad (3)$$

Calculamos los factoriales y sustituyendo:

$$\binom{5}{3} = \frac{120}{6 \times 2} = \frac{120}{12} = 10 \quad (4)$$

Ejemplo: Probabilidad de obtener 3 caras en 5 lanzamientos

Paso 3: Cálculo de la probabilidad

$$\begin{aligned}P(X = 3) &= 10 \times (0,5)^3 \times (0,5)^2 \\ &= 0,3125\end{aligned}$$

Resultado final: $P(X = 3) = 0,3125 \quad (31,25 \%) \quad (5)$

Esto significa que la probabilidad de obtener exactamente 3 caras en 5 lanzamientos de una moneda justa es 31,25 %.

⁴La gráfica es simétrica, lo que indica que la probabilidad de obtener un número bajo de caras es igual a la probabilidad de obtener un número alto de caras.

⁵La mayor probabilidad se encuentra en 2 y 3 caras.


Ejemplo: Probabilidad de obtener 3 caras en 5 lanzamientos

Paso 3: Cálculo de la probabilidad

$$\begin{aligned}P(X = 3) &= 10 \times (0,5)^3 \times (0,5)^2 \\ &= 0,3125\end{aligned}$$

Resultado final: $P(X = 3) = 0,3125$ (31,25 %) (5)

Esto significa que la probabilidad de obtener exactamente 3 caras en 5 lanzamientos de una moneda justa es 31,25 %.



4 5

⁴La gráfica es simétrica, lo que indica que la probabilidad de obtener un número bajo de caras es igual a la probabilidad de obtener un número alto de caras.

⁵La mayor probabilidad se encuentra en 2 y 3 caras.



UNIVERSIDAD TÉCNICA
FEDERICO SANTA MARÍA

Procesamiento y Visualización de Datos

EIN087B - Ciencia de Datos

Profesor: Jorge Portilla G.

`jorge.portilla@usm.cl`

Departamento de Electrónica e Informática
Universidad Técnica Federico Santa María
Concepción, Chile